

PlanDiffusion：基于自回归图结构生成与

坐标扩散的文本驱动住宅平面图生成

[TODO: 作者信息]

摘要

[TODO: 等实验结果后填写。三句话结构：问题与现有局限 → 本文方法 → 实验结果。]

1 引言

住宅平面图的自动化生成是计算机辅助建筑设计的核心问题之一。理想的系统应当允许设计师以自然语言表达设计意图（如“客厅居中，两侧各有一间卧室，厨房通过走廊与卫生间相连”），并自动生成与描述一致、拓扑合理的矢量平面图。

早期工作主要依赖图约束或气泡图（bubble diagram）作为生成条件 [5, 7]。这类方法虽能输出几何上连贯的平面图，但气泡图本身仍需由设计师手工绘制，并未从根本上解决“从语言到图纸”的端到端生成问题。Architext [1] 率先将大语言模型引入平面图生成，但其文本描述由规则模板自动生成，语言单一，与真实设计需求存在较大差距。ChatHouseDiffusion [6] 进一步引入 prompt 引导，但生成过程缺乏对房间拓扑结构的显式建模，难以保证连通性等结构约束。

本文提出 **PlanDiffusion**，一种以图结构为中间表示的文本驱动平面图生成框架，整体流程如图 1 所示。核心思路是将生成任务分解为两个串联阶段：（1）**图拓扑生成**：以 LLaMA 自回归模型将文本描述转化为平面图的拓扑图结构，包括节点数量、邻接关系与房间类型；（2）**节点坐标扩散**：以图结构和文本为双重条件，通过去噪扩散概率模型（DDPM）生成每个顶点的二维坐标。显式的图结构中间表示使拓扑约束在扩散过程中始终可控，同时为坐标生成提供了强结构先验。

为支撑上述框架的训练，我们在 Architext_v1 [1] 基础上构建了 **PlanText-150K**，一个包含 149,609 条样本的大规模平面图-文本数据集。与原始数据集的模板式描述不同，我们调用 40 余个视觉语言模型（VLM）对每张平面图生成自然语言描述，并按模型质量优先级选取最佳结果，显著提升了文本标注的多样性与自然度。

本文的主要贡献如下：

- 提出以图结构为中间表示的两阶段文本驱动平面图生成框架，在保证拓扑合法性的同时实现端到端的语言条件生成；
- 设计了“BFS 生成树 + 补边”的图序列化格式，使任意连通图均可被自回归语言模型高效建模；
- 构建了 PlanText-150K 数据集，通过多模型 VLM 标注提供高质量自然语言描述，是目前规模最大的带文本标注的住宅平面图数据集之一；
- 设计了双流注意力去噪网络，同时利用邻接局部注意力和文本全局注意力实现图结构与语义的联合条件化。

2 相关工作

2.1 平面图生成

平面图生成方法大致可分为三类。

图约束方法。 House-GAN [5] 将房间邻接图作为条件，以关系生成对抗网络生成各房间的边界框，开创了以图约束驱动布局生成的范式。该类方法对拓扑结构有强控制能力，但需要用户预先提供手绘气泡图，限制了易用性。

扩散模型方法。 HouseDiffusion [7] 提出混合扩散模型，在连续坐标与离散房间标签上联合去噪，直接生成矢量多边形，取得了当时最优的几何质量。其同样以气泡图为输入条件，不支持自然语言驱动。

语言驱动方法。 Architext [1] 在 250k 合成平面图上微调 GPT 系列模型，实现了从自然语言描述到平面图的直接生成。Tell2Design [3] 构建了语言引导平面图数据集并探索了多种基线方法。ChatHouseDiffusion [6] 将扩散模型与 prompt 引导相结合，支持生成与编辑，但仍缺乏对拓扑结构的显式约束。

与上述工作不同，本文在文本和坐标之间引入显式图结构作为中间表示，同时具备语言可控性和拓扑保证。




图 1: PlanDiffusion 整体流程。左: Stage 1 以文本描述为条件, 通过 LLaMA 自回归推理生成图结构序列, 解析得到顶点图; 右: Stage 2 以顶点图和文本为条件, 通过 DDPM 逆扩散过程从高斯噪声 (\$t = 1000\$) 逐步恢复节点坐标 (\$t = 0\$)。

2.2 自回归图结构生成

将图结构序列化后用自回归模型建模是图生成的经典思路。You et al. [10] 提出 GraphRNN, 以节点-边交替序列逐步生成图结构。近年来, 基于 Transformer 的方法进一步提升了序列建模能力。DiGress [9] 将图生成建模为离散扩散过程, 在分子图和场景图上取得了优秀结果。GRAN [4] 通过自回归块生成稠密图, 提升了效率。

本文的图序列化方案受”将图展平为序列”思路的启发 [10], 采用”BFS 生成树 + 补边”格式, 使生成树部分 (长度固定为 \$N - 1\$) 与补边部分 (长度可变) 结构清晰, 便于自回归模型学习。

2.3 扩散模型在布局生成中的应用

DDPM [2] 提出去噪扩散概率模型后, 扩散过程被广泛应用于图像、点云、分子构象等结构化数据的生成。在布局生成方向, LayoutDM、DiffLayout 等工作将扩散模型引入 UI 布局、文档排版等任务, 取得了较好的多样性与质量均衡。HouseDiffusion [7] 将其引入矢量平面图, 验证了扩散模型在几何生成上的优越性。

本文的节点坐标扩散模块在 DDPM 框架下, 以图结构 (邻接矩阵) 和文本 (WordPiece token) 为双重条件, 通过双流注意力机制同时捕捉局部几何约束和全局语义信息, 与上述工作在条件化方式上存在本质区别。

3 方法

3.1 问题定义

给定自然语言描述 \$\mathcal{T}\$, 目标是生成对应的住宅平面图。我们将平面图表示为带属性的图 \$\mathcal{G} = (\mathcal{V}, \mathcal{E})\$, 其中 \$\mathcal{V}\$ 为节点集合 (房间多边形的角点), \$\mathcal{E}\$ 为边集合 (相邻角点间的连接关系)。每个节点 \$v_i\$ 附带二维坐标 \$\mathbf{c}_i \in \mathbb{R}^2\$ 和组合类型标签 \$y_i \in \{1, \dots, 32\}\$, 令 \$\mathbf{X} = [\mathbf{c}_1, \dots, \mathbf{c}_N]^\top \in \mathbb{R}^{N \times 2}\$, 邻接矩阵 \$\mathbf{A} \in \{0, 1\}^{N \times N}\$。

目标是学习联合分布 \$p(\mathbf{A}, \mathbf{X}, \mathbf{y} | \mathcal{T})\$, 我们将其分解为两个串联子问题:

$$p(\mathbf{A}, \mathbf{X}, \mathbf{y} | \mathcal{T}) = \underbrace{p_{\theta_1}(\mathbf{A} | \mathcal{T})}_{\text{Stage 1}} \cdot \underbrace{p_{\theta_2}(\mathbf{X}, \mathbf{y} | \mathbf{A}, \mathcal{T})}_{\text{Stage 2}} \quad (1)$$

(1) **图拓扑生成**: 自回归建模 \$p_{\theta_1}(\mathbf{A} | \mathcal{T})\$, 输出图的连接结构; (2) **节点坐标与类型扩散**: 以 \$(\mathbf{A}, \mathcal{T})\$ 为条件, 通过扩散模型建模 \$p_{\theta_2}(\mathbf{X}, \mathbf{y} | \mathbf{A}, \mathcal{T})\$。

3.2 数据集

现有平面图数据集的文本标注普遍依赖规则模板, 语言单一, 且缺乏结构化的图表示。Architext_v1 [1] 虽提供大规模合成平面图, 但其描述仅为简单模板句 (如 “a house with two bedrooms and one bathroom”), 不足以支撑文本条件生成的训练。为此, 我们在 Architext_v1 基础上构建了新的训练数据集, 引入顶点图表示与 VLM 生成的自然语言描述, 如图 2 所示。

顶点图表示 我们将平面图表示为**顶点图**: 以房间多边形的全部角点为节点, 以多边形边上相邻顶点的连接为边。由于多个房间可能共享同一顶点 (如卧室与走廊的公共墙角), 每个节点的类型定义为其所属全部房间类型的有序组合, 称为**组合类型 (combo type)**。与使用房间中心点的方案相比, 顶点图保留了平面图完整的几何拓扑信息, 并使图结构与几何形状之间保持一一对应。全部训练样本中共出现 32 种组合类型, 每种分配唯一整数 ID (1-32)。




图 2: 数据集样例。每条样本包含住宅平面图渲染 (左)、对应顶点图表示 (中) 及 VLM 自动生成的自然语言描述 (右)。顶点颜色表示组合类型, 边表示几何连接关系。

自然语言标注 我们将顶点图渲染为彩色平面图图像，调用多个视觉语言模型（Qwen 系列、DeepSeek-V3、Kimi 等，共 40 余个）对每张图生成自然语言描述，并按模型质量优先级选取最佳结果。标注要求直接陈述各房间的位置关系与连通关系，回避视觉指代词，使描述可独立于图像作为文本条件使用。

统计 最终数据集包含 **149,609** 条样本，每条样本含邻接矩阵（ 40×40 ）、节点坐标（ 40×2 ）、组合类型 ID（40）及文本描述（WordPiece 编码，训练只保留小于或等于 128 token 的数据）。数据集关键统计如表 1 所示。

表 1: 数据集统计

统计项	最小	均值	最大
样本总数		149,609	
节点数	9	22.4	40
边数	12	28.6	49
文本长度 (token)	33	81.8	145
单类型节点占比		60.7%	
多类型节点占比		39.3%	
Combo 类型总数		32	

3.3 统一词表

为使文本 token 与图结构 token 共存于同一序列空间，我们采用 BERT-base-uncased 的前 10,000 个 WordPiece token 作为文本词表，并在其后追加 84 个图结构专用 token，构成大小为 10,084 的统一词表，具体如表 2 所示。该词表同时被 Stage 1 和 Stage 2 共享。相较于在领域数据上重新训练 BPE，直接复用 BERT WordPiece 词表使系统更易与预训练语言模型对接，且对英文建筑描述具有良好的覆盖率。

表 2: 统一词表布局

ID 范围	Token	说明
0 – 9999	WordPiece token	文本词表 (BERT 前 10k)
10000	PAD	填充
10001	BOS_G	图序列起始
10002	EOS_G	图序列终止
10003	SEP	生成树与补边分隔符
10004–10043	N_k	节点数量 ($N = 1 \sim 40$)
10044–10083	节点 token	节点编号 (0~39)

3.4 阶段一：自回归图拓扑生成

3.4.1 图序列化格式

给定含 N 个节点的图，我们将其序列化为：

$$\underbrace{t_1 \dots t_L}_{\text{BPE 文本}} \text{ BOS_G } \underbrace{N_k}_{N \text{ 个节点}} \underbrace{p_1 \dots p_{N-1}}_{\text{生成树父节点}} \text{ SEP } \underbrace{i_1 j_1 \dots}_{\text{补边}} \text{ EOS_G } \quad (2)$$

其中生成树通过 BFS 遍历构建，父节点序列 $p_i = \text{NODE} + \text{parent}(i)$ 记录每个节点在 BFS 树中的父节点；补边为不属于生成树的额外边，每条边用两个 token 表示。这一“生成树 + 补边”格式结构规整（父节点序列长度固定为 $N - 1$ ），且任意连通图均可唯一表示。为增强多样性，对每张图从不同起始节点执行 BFS（增强 $\times 4$ ）。

图 3 展示了自回归生成过程中图结构的逐步构建：从部分父节点序列对应的局部生成树，到完整生成树，再逐步添加补边，最终恢复完整图拓扑。

令 $\mathbf{s} = (s_1, \dots, s_K)$ 为完整序列（含文本前缀），模型建模：

$$p_{\theta_1}(\mathbf{A} \mid \mathcal{T}) = \prod_{k \in \mathcal{I}_g} p_{\theta_1}(s_k \mid s_{<k}) \quad (3)$$

其中 $\mathcal{I}_g$ 为 BOS_G 之后的图 token 下标集合；文本部分 label 置 -100，不计入 loss。




图 3: 图序列化的自回归生成过程 (真实数据, $N = 10$)。蓝色实线为 BFS 生成树边, 红色虚线为补边。从左至右依次为: (1) 生成部分父节点 token 后的局部生成树; (2) 父节点序列生成完毕 (SEP 前) 的完整生成树; (3) 生成前两条补边后的图; (4) 所有补边生成完毕 (EOS_G 前) 的完整图。

3.4.2 模型结构

本阶段采用 LlamaForCausalLM [8] 为自回归主干, 配置为: 隐藏层维度 512, 8 层, 8 头, 前馈维度 1536, 词表大小 10,084, 约 20M 参数。

3.4.3 两阶段训练策略

直接在文本 + 图联合序列上训练易导致模型难以同时学习语言理解与图结构生成。为此, 我们采用两阶段训练:

预训练 (图结构预训练): 仅使用图序列部分 (BOS_G 之后), 令模型在不依赖文本条件的情况下先学习图结构语法, 训练 50 epoch。

微调 (文本条件微调): 以预训练权重初始化, 输入完整文本 + 图联合序列, loss 仅在图序列部分计算, 训练 100 epoch。

两阶段均采用 AdamW ($\beta_1=0.9$, $\beta_2=0.95$, $lr = 10^{-4}$, 余弦退火至 10^{-5}), $grad\ clip = 1.0$, FP16 混合精度。

3.5 阶段二: 节点坐标与类型联合扩散

3.5.1 联合扩散对象

坐标 $\mathbf{x}_0 \in \mathbb{R}^{2 \times N}$ 可直接在欧氏空间扩散。类型标签 $y_i \in \{1, \dots, 32\}$ 为离散量, 无法直接施加高斯噪声; 为此, 我们将其映射到连续嵌入空间:

$$\mathbf{e}_0^{(i)} = \text{Emb}(y_i) \in \mathbb{R}^d, \quad d = 384 \quad (4)$$

并在嵌入空间对 $\mathbf{e}_0^{(i)}$ 施加高斯扩散。这使坐标与类型可在统一的 Gaussian DDPM 框架下联合训练, 无需引入离散扩散机制。

3.5.2 前向过程

采用线性 beta 调度 ($\beta_t \in [10^{-4}, 0.02]$, $T = 1000$), 令 $\alpha_t = 1 - \beta_t$, $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s$ 。两路前向过程如图 4 所示, 分别为:

$$\mathbf{x}_t = \sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}) \quad (5)$$

$$\mathbf{e}_t^{(i)} = \sqrt{\bar{\alpha}_t} \mathbf{e}_0^{(i)} + \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\delta}^{(i)}, \quad \boldsymbol{\delta}^{(i)} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}) \quad (6)$$

3.5.3 去噪网络

去噪网络 f_θ 为双流注意力 Transformer (架构详见图 5), 接收加噪坐标、加噪类型嵌入、时间步、邻接矩阵和文本, 预测两路噪声:

$$(\hat{\boldsymbol{\epsilon}}_{\text{coord}}, \hat{\boldsymbol{\epsilon}}_{\text{type}}) = f_\theta(\mathbf{x}_t, \mathbf{E}_t, t, \mathbf{A}, \mathbf{m}, \mathcal{T}) \quad (7)$$




图 4: 节点图的前向扩散过程 ($t = 0 \rightarrow t = 1000$)。 $t = 0$ 为真实节点坐标, 随时间步增大逐渐被高斯噪声淹没, 至 $t = 1000$ 时坐标分布退化为标准正态分布。节点颜色表示组合类型。

其中 $\mathbf{E}_t = \{\mathbf{e}_t^{(i)}\}_{i=1}^N$ 为加噪类型嵌入矩阵。

节点特征融合 坐标特征与类型嵌入并非两条独立序列, 而是在输入阶段直接相加, 与时间步嵌入共同构成每个节点的**单一共享隐向量**:

$$\mathbf{h}_i^{(0)} = W_c \mathbf{x}_t^{(i)} + \mathbf{e}_t^{(i)} + \text{MLP}(\gamma(t)) \quad (8)$$

其中 $\gamma(t)$ 为正弦时间步编码, $W_c \in \mathbb{R}^{d \times 2}$ 。这一设计的关键在于: 坐标与类型信息在同一表示空间内相互耦合, 后续所有注意力计算均作用于这一融合向量。因此, 坐标与类型之间并无独立的 cross-attention 流, 而是通过共享向量在每一次注意力计算中隐式耦合。具体而言, 每个注意力头的 Q/K/V 均由融合向量线性投影得到:

$$\mathbf{Q}_i = W_Q \mathbf{h}_i^{(\ell)}, \quad \mathbf{K}_j = W_K \mathbf{h}_j^{(\ell)}, \quad \mathbf{V}_j = W_V \mathbf{h}_j^{(\ell)} \quad (9)$$

由于 $\mathbf{h}_j^{(\ell)}$ 同时携带坐标与类型信息, 注意力分数 $\mathbf{Q}_i \cdot \mathbf{K}_j^\top$ 及聚合值 $\sum_j \alpha_{ij} \mathbf{V}_j$ 均隐含了两者的联合感知。两个输出 head 也均从同一 $\mathbf{h}_i^{(L)}$ 读取, 使坐标噪声预测与类型噪声预测在整个去噪过程中保持相互感知。

双流注意力层 每层包含两条并行注意力流, 输出残差相加后经 FFN 处理:

$$\begin{aligned} \mathbf{h}_i^{(\ell+1)} = & \mathbf{h}_i^{(\ell)} + \text{Dropout}\left(\text{AdjAttn}(\mathbf{H}_{\text{node}}^{(\ell)})\right)_i \\ & + \text{Dropout}\left(\text{GlobalAttn}(\mathbf{H}_{\text{full}}^{(\ell)})\right)_i \end{aligned} \quad (10)$$

- **邻接局部注意力** AdjAttn: 仅对节点序列 $\mathbf{H}_{\text{node}}$ 计算, 注意力掩码由邻接矩阵决定:

$$M_{ij}^{\text{adj}} = \begin{cases} 0 & \text{若 } \mathbf{A}_{ij} = 1 \\ -\infty & \text{其他} \end{cases} \quad (11)$$

每个节点仅能关注直连邻居, 在保证图结构约束的同时, 使相邻节点之间的坐标与类型特征得以局部交换。

- **全局注意力** GlobalAttn: 对拼接序列 $\mathbf{H}_{\text{full}} = [\mathbf{H}_{\text{text}}; \mathbf{H}_{\text{node}}]$ 做无约束注意力, 使每个节点能跨越图结构感知全局布局与文本语义, 并使所有节点的融合特征 (含坐标与类型) 之间形成完全连接。文本嵌入通过可学习 BPE 嵌入层 (维度 $d = 384$) 获得, 无需预训练语言模型。

共堆叠 6 层, model_channels = 384, 6 头, dropout = 0.1。

3.5.4 训练目标

联合训练目标为:

$$\mathcal{L} = \mathcal{L}_{\text{coord}} + \lambda \mathcal{L}_{\text{type}} \quad (12)$$

Inputs




图 5: NodeDiffusionTransformer 架构图。输入的加噪坐标、加噪类型嵌入和时间步在 Fusion 模块融合为节点隐向量，拼接文本嵌入后经 6 层双流注意力编码器处理；最终节点特征分别经 Coordinate Head 和 Type Embedding Head 预测两路噪声 $\hat{\mathbf{e}}_{\text{coord}}$ 和 $\hat{\mathbf{e}}_{\text{type}}$ 。

$$\mathcal{L}_{\text{coord}} = \frac{\sum_i m_i \|\hat{\mathbf{e}}_{\text{coord},i} - \mathbf{e}_i\|^2}{2 \sum_i m_i} \quad (13)$$

$$\mathcal{L}_{\text{type}} = \frac{\sum_i m_i \|\hat{\mathbf{e}}_{\text{type},i} - \delta_i\|^2}{d \sum_i m_i} \quad (14)$$

其中 m_i 为节点有效掩码, $\lambda = 1.0$ 。 $\mathcal{L}_{\text{type}}$ 在嵌入空间预测类型噪声, 与 $\mathcal{L}_{\text{coord}}$ 共享扩散时间步, 同时起到对坐标预测的语义正则化作用。

优化器为 AdamW ($\text{lr} = 10^{-4}$, $\text{weight decay} = 10^{-4}$), $\text{grad clip} = 1.0$, $\text{batch} = 64$, $\text{total steps} = 200\text{k}$, FP16 混合精度。

3.5.5 推理: 坐标采样与类型恢复

逆过程执行标准 DDPM 采样 (1000 步):

$$p_{\theta_2}(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{A}, \mathcal{T}) = \mathcal{N}(\mathbf{x}_{t-1}; \boldsymbol{\mu}_\theta, \tilde{\beta}_t \mathbf{I}) \quad (15)$$

$$\boldsymbol{\mu}_\theta = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1 - \alpha_t}} \hat{\mathbf{e}}_\theta \right) \quad (16)$$

类型嵌入路同步采样得到 $\hat{\mathbf{e}}_0^{(i)}$, 再通过最近邻查找恢复离散类型:

$$\hat{y}_i = \arg \min_{k \in \{1, \dots, 32\}} \left\| \hat{\mathbf{e}}_0^{(i)} - \text{Emb}(k) \right\|_2 \quad (17)$$

3.6 推理流程

给定文本 $\mathcal{T}$, 完整推理分三步: (1) Stage 1 自回归生成图序列 token, 解析得邻接矩阵 $\mathbf{A}$ 与节点数 N ; (2) Stage 2 以 $(\mathbf{A}, \mathbf{m}, \mathcal{T})$ 为条件, 从 $(\mathbf{x}_T, \{\mathbf{e}_T^{(i)}\}) \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 出发执行 1000 步逆扩散, 得到节点坐标 $\hat{\mathbf{X}}$ 与类型 $\hat{\mathbf{y}}$; (3) 反归一化坐标, 结合 $\mathbf{A}$ 与 $\hat{\mathbf{y}}$ 渲染矢量平面图。

最小度约束 Stage 1 在生成补边序列 (SEP 之后) 时, 施加**最小度约束**: 若当前图中存在度数小于 2 的节点, 则在 logit 采样前将 EOS_G 对应的 logit 置为 $-\infty$, 强制模型继续生成补边, 直至所有节点满足 $\deg(v_i) \geq 2$ 。

该约束的几何动机在于: 顶点图中每个节点代表房间多边形的一个角点, 角点至少需连接两条边才能构成有效的多边形转角。度数为 1 的悬挂节点无法参与闭合多边形的构造, 会导致后处理渲染时出现孤立线段或破碎轮廓。通过在推理阶段以零额外训练代价强制施加此约束, 可显著提升生成图的几何合法率。

完整推理流程如算法 1 所示。

4 实验

4.1 实验设置

评估指标 我们从几何质量、拓扑合法性和文本一致性三个维度评估生成结果:

- **图有效率 (Graph Validity Rate, GVR)**: 生成图中连通且无孤立节点的样本占比, 反映 Stage 1 的拓扑合法性。
- **坐标 RMSE (Coord-RMSE)**: 在已知真实坐标的情况下, 去噪预测坐标与真实坐标的均方根误差 (像素单位), 衡量 Stage 2 的坐标回归精度。
- **类型准确率 (Type Acc.)**: 最近邻恢复的节点类型与真实类型的匹配率, 衡量类型嵌入扩散的语义保持能力。
- **FID**: 在渲染后的平面图图像上计算 Fréchet Inception Distance, 衡量生成分布与真实分布的整体视觉相似度。

基线方法 由于本文与现有方法在输入模态上存在根本差异, 对比以方法特性说明为主:

- **Architext [1]**: 在 Architext_v1 数据集上微调 GPT 系列模型, 以自然语言描述直接生成平面图。

Algorithm 1 PlanDiffusion 推理

Require: 文本描述 $\mathcal{T}$

Ensure: 节点坐标 $\hat{\mathbf{X}}$, 节点类型 $\hat{\mathbf{y}}$, 邻接矩阵 $\mathbf{A}$

```
1: Stage 1: 图拓扑生成
2: 以  $\mathcal{T}$  为条件, 自回归采样生成树序列 token
3: while 未采样到 EOS_G do
4:   采样下一个 token  $s \sim p_{\theta_1}(\cdot | s_{<k})$ 
5:   if  $s = \text{EOS\_G}$  and  $\exists i: \deg(v_i) < 2$  then
6:     将 EOS_G 的 logit 置为  $-\infty$ , 重新采样 {最小度约束}
7:   end if
8: end while
9: 解析序列得  $\mathbf{A} \in \{0, 1\}^{N \times N}$ , 节点掩码  $\mathbf{m}$ 
10: Stage 2: 坐标与类型扩散
11: 采样初始噪声  $\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ ,  $\mathbf{E}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 
12: for  $t = T, T-1, \dots, 1$  do
13:    $(\hat{\mathbf{e}}_{\text{coord}}, \hat{\mathbf{e}}_{\text{type}}) = f_{\theta}(\mathbf{x}_t, \mathbf{E}_t, t, \mathbf{A}, \mathbf{m}, \mathcal{T})$ 
14:    $\mathbf{x}_{t-1} \leftarrow \text{DDPM 逆步}(\mathbf{x}_t, \hat{\mathbf{e}}_{\text{coord}}, t)$ 
15:    $\mathbf{E}_{t-1} \leftarrow \text{DDPM 逆步}(\mathbf{E}_t, \hat{\mathbf{e}}_{\text{type}}, t)$ 
16: end for
17:  $\hat{\mathbf{X}} \leftarrow \mathbf{x}_0$ 
18:  $\hat{\mathbf{y}}_i = \arg \min_k \|\hat{\mathbf{e}}_0^{(i)} - \text{Emb}(k)\|_2, \forall i$ 
19: return  $\hat{\mathbf{X}}, \hat{\mathbf{y}}, \mathbf{A}$ 
```

其文本描述由规则模板生成, 语言单一, 且不建模显式图结构。

- **HouseDiffusion** [7]: 以气泡图 (bubble diagram) 为条件, 通过混合扩散模型生成矢量多边形平面图。几何质量优秀, 但需手工绘制气泡图, 不支持自然语言输入。
- **ChatHouseDiffusion** [6]: 在 HouseDiffusion 基础上引入 prompt 引导, 支持文本条件生成与编辑, 但缺乏对拓扑结构的显式约束。

实现细节 [TODO: 待补充: 训练硬件、训练时长、推理时间。]

4.2 主实验结果

[TODO: 待写: 与 Architext 基线的对比。]

4.3 消融实验

[TODO: 待写。]

4.4 定性结果

[TODO: 待写: 生成结果可视化。]

5 结论

本文提出了 PlanDiffusion, 一种以图结构为中间表示的文本驱动住宅平面图生成框架。通过将生成任务分解为自回归图拓扑生成 (Stage 1) 和节点坐标扩散 (Stage 2) 两个阶段, 本方法在保证房间连通拓扑合法性的同时, 实现了从自然语言到矢量平面图的端到端生成。

为支撑模型训练, 我们构建了 PlanText-150K 数据集, 包含 149,609 条具有高质量自然语言描述的平面图样本, 是目前规模最大的带文本标注住宅平面图数据集之一。

[TODO: 实验结果完成后补充定量结论。]

局限性 本文方法存在以下几点局限: (1) Stage 2 采用标准 DDPM 1000 步采样, 单次推理耗时较长, 尚未引入 DDIM 等加速采样策略; (2) Stage 1 自回归生成偶尔产生不连通图或格式不合法序列, 需要后处理过滤, 影响端到端可靠性; (3) 顶点图表示依赖多边形角点, 生成结果须经后处理才能转化为完整矢量房间多边形; (4) 文本编码采用 BERT WordPiece 英文词表, 对中文或其他语言描述的支持有限。

未来工作将探索更长文本条件下的生成质量提升、多楼层平面图生成, 以及基于用户反馈的交互式编辑能力。

参考文献

- [1] T. Galanos, A. Liapis, and G. N. Yannakakis. Architext: Language-driven generative architecture design. *arXiv preprint arXiv:2303.07519*, 2023.
- [2] J. Ho, A. Jain, and P. Abbeel. Denoising diffusion probabilistic models. *NeurIPS*, 2020.
- [3] S. Leng, Y. Zhou, H. Hao, X. Shi, and X. Lu. Tell2design: A dataset for language-guided floor plan generation. In *ACL*, 2023.
- [4] R. Liao, Y. Li, Y. Song, S. Wang, W. Hamilton, D. Duvenaud, R. Urtasun, and R. Zemel. Efficient graph generation with graph recurrent attention networks. In *NeurIPS*, 2019.
- [5] N. Nauata, K.-H. Chang, C.-Y. Cheng, G. Mori, and Y. Furukawa. House-gan: Relational generative adversarial networks for graph-constrained house layout generation. In *ECCV*, 2020.
- [6] S. Qin, C. He, Q. Chen, S. Yang, W. Liao, Y. Gu, and X. Lu. Chathousediffusion: Prompt-guided generation and editing of floor plans. In *AAAI*, 2025.
- [7] M. A. Shabani, S. Hosseini, and Y. Furukawa. Housediffusion: Vector floorplan generation via a diffusion model with discrete and continuous denoising. In *CVPR*, 2023.
- [8] H. Touvron, T. Lavril, G. Izacard, et al. Llama: Open and efficient foundation language models. *arXiv preprint arXiv:2302.13971*, 2023.
- [9] C. Vignac, I. Krawczuk, A. Siraudin, B. Wang, V. Cevher, and P. Frossard. Digress: Discrete denoising diffusion for graph generation. In *ICLR*, 2023.
- [10] J. You, R. Ying, X. Ren, W. Hamilton, and J. Leskovec. Graphrnn: Generating realistic graphs with deep auto-regressive models. In *ICML*, 2018.