

PlanDiffusion: 基于自回归图结构生成与

坐标扩散的文本驱动住宅平面图生成

[TODO: 作者信息]

摘要

[TODO: 等实验结果后填写。三句话结构: 问题与现有局限 → 本文方法 → 实验结果。]

1 引言

住宅平面图的自动化生成是计算机辅助建筑设计的核心问题之一。理想的系统应当允许设计师以自然语言表达设计意图（如“客厅居中，两侧各有一间卧室，厨房通过走廊与卫生间相连”），并自动生成与描述一致、拓扑合理的矢量平面图。

早期工作主要依赖图约束或气泡图（bubble diagram）作为生成条件 [8, 12]。这类方法虽能输出几何上连贯的平面图，但气泡图本身仍需由设计师手工绘制，并未从根本上解决“从语言到图纸”的端到端生成问题。Architext [2] 率先将大语言模型引入平面图生成，但其文本描述由规则模板自动生成，语言单一，与真实设计需求存在较大差距。ChatHouseDiffusion [10] 进一步引入 prompt 引导，但生成过程缺乏对房间拓扑结构的显式建模，难以保证连通性等结构约束。

本文提出 **PlanDiffusion**，一种以图结构为中间表示的文本驱动平面图生成框架，整体流程如图 1 所示。核心思路是将生成任务分解为三个串联阶段：（1）**图拓扑生成**：以 LLaMA 自回归模型将文本描述转化为平面图的拓扑图结构，包括节点数量与邻接关系；（2）**节点坐标扩散**：以图结构和文本为双重条件，通过去噪扩散概率模型（DDPM）生成每个顶点的二维坐标；（3）**节点类型预测**：以生成坐标、图结构和文本为条件，通过独立分类器预测每个节点的房间组合类型。显式的图结构中间表示使拓扑约束在扩散过程中始终可控，同时为坐标生成提供了强结构先验；类型预测与坐标扩散完全解耦，在干净坐标上以纯监督方式训练。

为支撑上述框架的训练，我们在 Architext_v1 [2] 基础上构建了 **PlanText-150K**，一个包含 149,609 条样本的大规模平面图-文本数据集。与原始数据集的模板式描述不同，我们调用 40 余个视觉语言模型（VLM）对每张平面图生成自然语言描述，并按模型质量优先级选取最佳结果，显著提升了文本标注的多样性与自然度。

本文的主要贡献如下：

- 提出以图结构为中间表示的两阶段文本驱动平面图生成框架，在保证拓扑合法性的同时实现端到端的语言条件生成；
- 设计了“BFS 生成树 + 补边”的图序列化格式，使任意连通图均可被自回归语言模型高效建模；
- 构建了 PlanText-150K 数据集，通过多模型 VLM 标注提供高质量自然语言描述，是目前规模最大的带文本标注的住宅平面图数据集之一；
- 设计了双流注意力去噪网络（NodeDiffusionTransformer），同时利用邻接局部注意力与文本全局注意力实现图结构与语义的联合条件化，在给定图结构条件下高精度恢复节点坐标。

2 相关工作

2.1 平面图生成

平面图生成方法大致可分为三类。

图约束方法。 House-GAN [8] 将房间邻接图作为条件，以关系生成对抗网络生成各房间的边界框，开创了以图约束驱动布局生成的范式。该类方法对拓扑结构有强控制能力，但需要用户预先提供手绘气泡图，限制了易用性。

扩散模型方法。 HouseDiffusion [12] 提出混合扩散模型，在连续坐标与离散房间标签上联合去噪，直接生成矢量多边形，取得了当时最优的几何质量。其同样以气泡图为输入条件，不支持自然语言驱动。

语言驱动方法。 Architext [2] 在 250k 合成平面图上微调 GPT 系列模型，实现了从自然语言描述到平面图的直接生成。Tell2Design [4] 构建了语言引导平面图数据集并探索了多种基线方法。ChatHouseDiffusion [10] 将扩散模型与 prompt 引导相结合，支持生成与编辑，但仍缺乏对拓扑结构的显式约束。




图 1: PlanDiffusion 整体流程。左：图拓扑生成阶段以文本描述为条件，通过 LLaMA 自回归推理生成图结构序列，解析得到顶点图；右：节点坐标扩散阶段以顶点图和文本为条件，通过 DDPM 逆扩散过程从高斯噪声 ($t = 1000$) 逐步恢复节点坐标与类型 ($t = 0$)。

与上述工作不同，本文在文本和坐标之间引入显式图结构作为中间表示，同时具备语言可控性和拓扑保证。

2.2 自回归图结构生成

将图结构序列化后用自回归模型建模是图生成的经典思路。You et al. [15] 提出 GraphRNN，以节点-边交替序列逐步生成图结构。近年来，基于 Transformer 的方法进一步提升了序列建模能力。DiGress [14] 将图生成建模为离散扩散过程，在分子图和场景图上取得了优秀结果。GRAN [5] 通过自回归块生成稠密图，提升了效率。

本文的图序列化方案受“将图展平为序列”思路的启发 [15]，采用“BFS 生成树 + 补边”格式，使生成树部分（长度固定为 $N - 1$ ）与补边部分（长度可变）结构清晰，便于自回归模型学习。

2.3 扩散模型在布局生成中的应用

DDPM [3] 提出去噪扩散概率模型后，扩散过程被广泛应用于图像、点云、分子构象等结构化数据的生成。在布局生成方向，LayoutDM、DiffLayout 等工作将扩散模型引入 UI 布局、文档排版等任务，取得了较好的多样性与质量均衡。HouseDiffusion [12] 将其引入矢量平面图，验证了扩散模型在几何生成上的优越性。

本文的节点坐标扩散模块在 DDPM 框架下，以图结构（邻接矩阵）和文本（WordPiece token）为双重条件，通过双流注意力机制同时捕捉局部几何约束和全局语义信息，与上述工作在条件化方式上存在本质区别。

3 方法

3.1 问题定义

给定自然语言描述 $\mathcal{T}$ ，目标是生成对应的住宅平面图。我们将平面图表示为带属性的图 $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ ，其中 $\mathcal{V}$ 为节点集合（房间多边形的角点）， $\mathcal{E}$ 为边集合（相邻角点间的连接关系）。每个节点 v_i 附带二维坐标 $\mathbf{c}_i \in \mathbb{R}^2$ 和组合类型标签 $y_i \in \{1, \dots, 32\}$ ，令 $\mathbf{X} = [\mathbf{c}_1, \dots, \mathbf{c}_N]^\top \in \mathbb{R}^{N \times 2}$ ，邻接矩阵 $\mathbf{A} \in \{0, 1\}^{N \times N}$ 。

目标是学习联合分布 $p(\mathbf{A}, \mathbf{X}, \mathbf{y} | \mathcal{T})$ ，我们将其分解为三个串联子问题：

$$p(\mathbf{A}, \mathbf{X}, \mathbf{y} | \mathcal{T}) = \underbrace{p_{\theta_1}(\mathbf{A} | \mathcal{T})}_{\text{图拓扑生成}} \cdot \underbrace{p_{\theta_2}(\mathbf{X} | \mathbf{A}, \mathcal{T})}_{\text{坐标扩散}} \cdot \underbrace{p_{\theta_3}(\mathbf{y} | \mathbf{X}, \mathbf{A}, \mathcal{T})}_{\text{类型预测}} \quad (1)$$

(1) **图拓扑生成**：自回归建模 $p_{\theta_1}(\mathbf{A} | \mathcal{T})$ ，输出图的连接结构与节点数量；(2) **节点坐标扩散**：以 $(\mathbf{A}, \mathcal{T})$ 为条件，通过 DDPM 建模 $p_{\theta_2}(\mathbf{X} | \mathbf{A}, \mathcal{T})$ ；(3) **节点类型预测**：以生成坐标 $\mathbf{X}$ 、图结构 $\mathbf{A}$ 和文本 $\mathcal{T}$ 为条件，独立分类器建模 $p_{\theta_3}(\mathbf{y} | \mathbf{X}, \mathbf{A}, \mathcal{T})$ 。三个模型完全解耦训练，推理时串联执行。

3.2 数据集

现有平面图数据集的文本标注普遍依赖规则模板，语言单一，且缺乏结构化的图表示。Architext_v1 [2] 虽提供大规模合成平面图，但其描述仅为简单模板句（如 “a house with two bedrooms and one bathroom”），不足以支撑文本条件生成的训练。为此，我们在 Architext_v1 基础上构建了新的训练数据集，

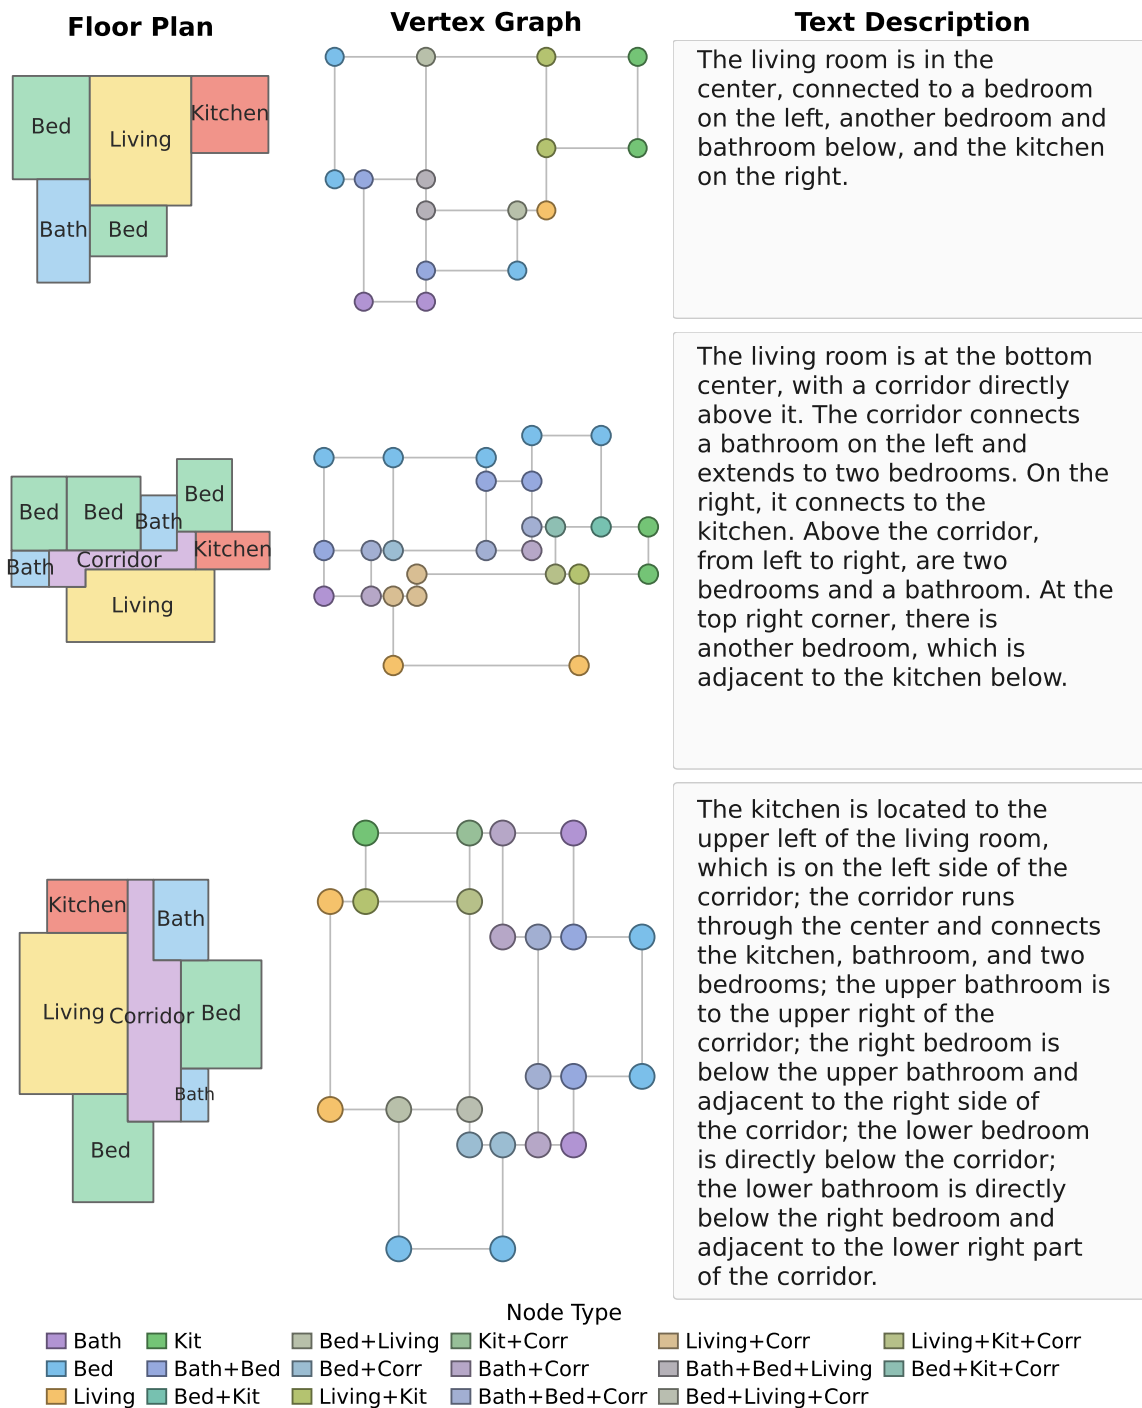


图 2: 数据集样例。每条样本包含住宅平面图渲染 (左)、对应顶点图表示 (中) 及 VLM 自动生成的自然语言描述 (右)。顶点颜色表示组合类型, 边表示几何连接关系。

引入顶点图表示与 VLM 生成的自然语言描述，如图 2 所示。

顶点图表示 我们将平面图表示为**顶点图**：以房间多边形的全部角点为节点，以多边形边上相邻顶点的连接为边。由于多个房间可能共享同一顶点（如卧室与走廊的公共墙角），每个节点的类型定义为其所属全部房间类型的有序组合，称为**组合类型 (combo type)**。与使用房间中心点的方案相比，顶点图保留了平面图完整的几何拓扑信息，并使图结构与几何形状之间保持一一对应。房间类型按固定字母序排列后取有序并集作为组合键，例如仅属于卫生间的顶点为类型 1 (bathroom)，同时属于卫生间与卧室公共墙角的顶点为类型 8 (bathroom + bedroom)。全部训练样本中共出现 32 种组合类型，每种分配唯一整数 ID (1-32)，完整映射见附录表 7。

自然语言标注 我们将顶点图渲染为彩色平面图图像，调用多个视觉语言模型 (Qwen 系列、DeepSeek-V3、Kimi 等，共 40 余个) 对每张图生成自然语言描述，并按模型质量优先级选取最佳结果。标注要求直接陈述各房间的位置关系与连通关系，回避视觉指代词，使描述可独立于图像作为文本条件使用。

统计 最终数据集包含 **149,609** 条样本（原始 150,000 条中过滤掉文本超过 224 token 的 391 条），每条样本含邻接矩阵 (40×40)、节点坐标 (40×2)、组合类型 ID (40) 及 WordPiece 文本描述。数据集关键统计如表 1 所示。

表 1: 数据集统计

统计项	最小	均值	最大
样本总数		149,609	
节点数	9	22.4	40
边数	12	28.6	50
文本长度 (token)	33	81.8	149
单类型节点占比		41.1%	
多类型节点占比		58.9%	
Combo 类型总数		32	

3.3 统一词表

为使文本 token 与图结构 token 共存于同一序列空间，我们采用 BERT-base-uncased 的前 10,000 个 WordPiece token 作为文本词表，并在其后追加 84 个图结构专用 token，构成大小为 10,084 的统一词表，具体如表 2 所示。图结构专用 token 仅用于图拓扑生成阶段；坐标扩散与类型预测阶段的文本嵌入层仅使用前 10,000 个 WordPiece token。

表 2: 统一词表布局

ID 范围	Token	说明
0 – 9999	WordPiece token	文本词表 (BERT 前 10k)，三阶段共用
10000	PAD	填充
10001	BOS_G	图序列起始
10002	EOS_G	图序列终止
10003	SEP	生成树与补边分隔符
10004–10043	N_k	节点数量 ($N = 1\sim 40$)，仅图拓扑阶段
10044–10083	节点 token	节点编号 (0~39)，仅图拓扑阶段

3.4 图拓扑生成

3.4.1 图序列化格式

给定含 N 个节点的图，我们将其序列化为：

$$\underbrace{t_1 t_2 \cdots t_L}_{\text{BPE 文本}} \text{BOS_G} \underbrace{N_k}_{N \text{ 个节点}} \underbrace{p_1 p_2 p_3 \cdots p_{N-1}}_{\text{生成树父节点}} \text{SEP} \underbrace{i_1 j_1 i_2 j_2 \cdots}_{\text{补边}} \text{EOS_G} \quad (2)$$

其中生成树通过 BFS 遍历构建，父节点序列 $p_i = \text{NODE} + \text{parent}(i)$ 记录每个节点在 BFS 树中的父节点；补边为不属于生成树的额外边，每条边用两个 token 表示。这一“生成树 + 补边”格式结构规整（父节点序列长度固定为 $N-1$ ），且任意连通图均可唯一表示。为增强多样性，对每张图从不同起始节点执行 BFS（增强 ×6）。




图 3: 图序列化的自回归生成过程 (真实数据, $N = 10$)。蓝色实线为 BFS 生成树边, 红色虚线为补边。从左至右依次为: (1) 生成部分父节点 token 后的局部生成树; (2) 父节点序列生成完毕 (SEP 前) 的完整生成树; (3) 生成前两条补边后的图; (4) 所有补边生成完毕 (EOS_G 前) 的完整图。

图 3 展示了自回归生成过程中图结构的逐步构建: 从部分父节点序列对应的局部生成树, 到完整生成树, 再逐步添加补边, 最终恢复完整图拓扑。

令 $\mathbf{s} = (s_1, \dots, s_K)$ 为完整序列 (含文本前缀), 模型建模:

$$p_{\theta_1}(\mathbf{A} \mid \mathcal{T}) = \prod_{k \in \mathcal{I}_g} p_{\theta_1}(s_k \mid s_{<k}) \quad (3)$$

其中 $\mathcal{I}_g$ 为 BOS_G 之后的图 token 下标集合; 文本部分 label 置 -100, 不计入 loss。

3.4.2 模型结构

本阶段采用 LlamaForCausalLM [13] 为自回归主干, 配置为: 隐藏层维度 512, 8 层, 8 头, 前馈维度 1536, 词表大小 10,084, 约 20M 参数。

3.4.3 训练设置

采用 AdamW [6] ($\beta_1=0.9$, $\beta_2=0.95$, $\text{lr} = 10^{-4}$, 余弦退火至 10^{-5}), $\text{grad clip} = 1.0$, FP16 混合精度 [7], 训练 150 epoch。

3.5 节点坐标扩散

3.5.1 前向过程

以生成的邻接矩阵 $\mathbf{A}$ 和文本 $\mathcal{T}$ 为条件, 对节点坐标 $\mathbf{X} \in \mathbb{R}^{N \times 2}$ 施加高斯 DDPM。采用余弦 (cosine) 噪声调度 [9] ($T = 1000$):

$$\bar{\alpha}_t = \frac{f(t)}{f(0)}, \quad f(t) = \cos^2\left(\frac{t/T + 0.008}{1.008} \cdot \frac{\pi}{2}\right), \quad \beta_t = 1 - \frac{\bar{\alpha}_t}{\bar{\alpha}_{t-1}} \quad (4)$$

令 $\alpha_t = 1 - \beta_t$, $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s$, 前向过程为:

$$\mathbf{x}_t = \sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}) \quad (5)$$

$t = 0$ 为真实节点坐标, 随时间步增大逐渐被高斯噪声淹没, 至 $t = 1000$ 时坐标分布退化为标准正态分布, 如图 4 所示。

3.5.2 去噪网络

去噪网络 f_{θ_2} (NodeDiffusionTransformer) 接收加噪坐标 $\mathbf{x}_t$ 、时间步 t 、邻接矩阵 $\mathbf{A}$ 、节点掩码 $\mathbf{m}$ 和文本 $\mathcal{T}$, 预测坐标噪声:

$$\hat{\boldsymbol{\epsilon}}_{\text{coord}} = f_{\theta_2}(\mathbf{x}_t, t, \mathbf{A}, \mathbf{m}, \mathcal{T}) \quad (6)$$

去噪网络整体架构如图 5 所示。




图 4: 节点图的前向扩散过程 ($t = 1000 \rightarrow t = 0$, 从左上至右下蛇形排列)。扩散面板中节点以灰色圆表示; 最右图 (Node Types) 还原 $t = 0$ 坐标后按组合类型着色, 展示最终类型预测结果。箭头标注各阶段操作名称。

节点特征初始化 坐标特征与时间步嵌入直接相加, 构成每个节点的初始隐向量:

$$\mathbf{h}_i^{(0)} = W_c \mathbf{x}_t^{(i)} + \text{MLP}(\gamma(t)) \quad (7)$$

其中 $\gamma(t)$ 为正弦时间步编码, $W_c \in \mathbb{R}^{d \times 2}$, $d = 384$ 。

双流注意力层 每层包含两条并行注意力流, 输出残差相加后经 FFN 处理:

$$\mathbf{h}_i^{(\ell+1)} = \mathbf{h}_i^{(\ell)} + \text{Dropout}\left(\text{AdjAttn}(\mathbf{H}_{\text{node}}^{(\ell)})\right)_i + \text{Dropout}\left(\text{GlobalAttn}(\mathbf{H}_{\text{full}}^{(\ell)})\right)_i \quad (8)$$

- **邻接局部注意力** AdjAttn: 仅对节点序列 $\mathbf{H}_{\text{node}}$ 计算, 注意力掩码由邻接矩阵决定:

$$M_{ij}^{\text{adj}} = \begin{cases} 0 & \text{若 } \mathbf{A}_{ij} = 1 \\ -\infty & \text{其他} \end{cases} \quad (9)$$

每个节点仅能关注直连邻居, 使相邻节点之间的坐标特征得以局部交换。

- **全局注意力** GlobalAttn: 对节点序列 $\mathbf{H}_{\text{node}}$ 做无掩码的全局自注意力, 使每个节点能感知全局布局信息。文本语义则由每层独立的交叉注意力 (CrossAttn, $Q = \mathbf{H}_{\text{node}}$, $K=V = \mathbf{H}_{\text{text}}$) 接入, 文本特征由冻结的 BERT-base-uncased 编码后经线性投影 ($768 \rightarrow d$) 得到。

共堆叠 6 层, $d = 384$, 6 头, dropout = 0.1, 约 15M 参数。

坐标预测头 编码器输出即为 N 个节点的隐向量 $\{\mathbf{h}_i^{(L)}\}_{i=1}^N \in \mathbb{R}^{N \times d}$ (文本语义已通过各层交叉注意力融合, 序列中始终只含节点 token), 对每个节点独立预测坐标噪声:

$$\hat{\epsilon}_{\text{coord},i} = \text{Linear}(192 \rightarrow 2) \circ \text{Linear}(384 \rightarrow 192) \circ \text{ReLU} \circ \text{Linear}(384 \rightarrow 384) \left(\mathbf{h}_i^{(L)} \right) \quad (10)$$




图 5: NodeDiffusionTransformer 架构图。输入的加噪坐标 $\mathbf{x}_t$ 经坐标投影与时间步嵌入相加，构成节点初始隐向量；拼接文本嵌入后经 6 层双流注意力编码器处理；最终节点特征经 Coordinate Head 预测坐标噪声 $\hat{\epsilon}_{\text{coord}}$ 。

3.5.3 训练目标

训练目标为有效节点上的 MSE:

$$\mathcal{L}_{\text{coord}} = \frac{\sum_i m_i \|\hat{\epsilon}_{\text{coord},i} - \epsilon_i\|^2}{2 \sum_i m_i} \quad (11)$$

其中 m_i 为节点有效掩码 (padding 节点不计入 loss)。

优化器为 AdamW [6] ($\text{lr} = 10^{-4}$, $\text{weight decay} = 10^{-4}$), $\text{grad clip} = 1.0$, $\text{batch} = 64$, $\text{total steps} = 200\text{k}$, FP16 混合精度 [7]。训练数据由原始图通过随机节点重排增强 $\times 8$ 。

3.5.4 推理: DDPM 逆采样

执行标准 DDPM 逆过程 (1000 步):

$$\mathbf{x}_{t-1} \sim \mathcal{N}\left(\boldsymbol{\mu}_\theta, \tilde{\beta}_t \mathbf{I}\right), \quad \boldsymbol{\mu}_\theta = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \hat{\epsilon}_{\text{coord}} \right) \quad (12)$$

从 $\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 出发, 逐步去噪得到 $\hat{\mathbf{X}} = \mathbf{x}_0$ 。

3.6 节点类型预测

3.6.1 解耦设计动机

节点类型 $y_i \in \{1, \dots, 32\}$ 为离散标签, 在扩散完成、获得干净坐标 $\hat{\mathbf{X}}$ 后, 可将类型预测视为以 $(\hat{\mathbf{X}}, \mathbf{A}, \mathcal{T})$ 为条件的独立分类任务。这一解耦设计避免了离散扩散或嵌入空间最近邻查找的复杂性, 且使类型分类器可在真实坐标 ($T = 0$) 上以强监督充分训练, 不受扩散噪声干扰。

3.6.2 模型结构

NodeTypeClassifier 与 **NodeDiffusionTransformer** 结构同构——均采用双流 EncoderLayer (邻接局部注意力 + 全局注意力), 但超参数独立, 权重完全不共享, 训练亦完全分离。**NodeTypeClassifier** 的配置为 $d = 384$, 4 层, 6 头, $\text{dropout} = 0.4$; **NodeDiffusionTransformer** 为 $d = 384$, 6 层, 6 头, $\text{dropout} = 0.1$; 两者结构同构但超参数独立, 权重完全不共享, 训练亦完全分离。两者的对比结构如图 6 所示, 关键差异如下:




图 6: NodeDiffusionTransformer 与 NodeTypeClassifier 结构对比。两者均采用同构的双流编码器设计, 但输入端 (有无时间步嵌入) 与输出头不同, 超参数与权重完全独立。

- **无时间步嵌入**: 输入始终为干净坐标 ($t = 0$), 节点初始隐向量为:

$$\mathbf{h}_i^{(0)} = W_c \mathbf{x}_0^{(i)}, \quad W_c \in \mathbb{R}^{d \times 2} \quad (13)$$

- **类型预测头**：替换坐标头，对每个节点输出 33 维 logit（0 为 padding，1-32 为有效类型）：

$$\hat{\mathbf{z}}_i = \text{Linear}(d \rightarrow 33) \circ \text{ReLU} \circ \text{Linear}(d \rightarrow d) \circ \text{LayerNorm}(\mathbf{h}_i^{(L)}) \quad (14)$$

3.6.3 训练目标

采用交叉熵损失，padding 节点 ($y_i = 0$) 不计入：

$$\mathcal{L}_{\text{type}} = -\frac{1}{\sum_i m_i} \sum_i m_i \log \frac{\exp(\hat{z}_{i,y_i})}{\sum_{k=1}^{32} \exp(\hat{z}_{i,k})} \quad (15)$$

评估指标为有效节点上的分类准确率：

$$\text{Acc} = \frac{\sum_i m_i \cdot \mathbf{1}[\arg \max_k \hat{z}_{i,k} = y_i]}{\sum_i m_i} \quad (16)$$

优化器为 AdamW [6] (lr = 10^{-4} , weight decay = 10^{-4}), grad clip = 1.0, batch = 64, total steps = 500k, FP16 混合精度 [7]。

3.6.4 推理：直接分类

在推理阶段，NodeTypeClassifier 接收扩散生成的坐标 $\hat{\mathbf{X}}$ 作为输入，输出每个节点的类型标签：

$$\hat{y}_i = \arg \max_{k \in \{1, \dots, 32\}} \hat{z}_{i,k} \quad (17)$$

3.7 推理流程

给定文本 $\mathcal{T}$ ，完整推理分四步：

- (1) **图拓扑生成**：自回归生成图序列 token，解析得邻接矩阵 $\mathbf{A}$ 与节点数 N 。
- (2) **坐标扩散**：以 $(\mathbf{A}, \mathbf{m}, \mathcal{T})$ 为条件，从 $\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 出发执行 1000 步逆扩散，得到节点坐标 $\hat{\mathbf{X}}$ 。
- (3) **节点类型预测**：以 $(\hat{\mathbf{X}}, \mathbf{A}, \mathcal{T})$ 为条件，NodeTypeClassifier 输出每个节点的组合类型 $\hat{y}_i \in \{1, \dots, 32\}$ ，并将其解码为该节点所属的房间类型集合。
- (4) **面提取与房间类型投票**：以半边遍历 (half-edge traversal) 在平面图 $(\hat{\mathbf{X}}, \mathbf{A})$ 上提取所有有界面，每个面对应一个房间多边形。对每个面 f_k ，采用特异性评分决定其房间类型：

$$r_k = \arg \max_t \frac{\text{fc}_k(t)}{\text{ec}_k(t) + 1} \quad (18)$$

其中 $\text{fc}_k(t)$ 为面内含类型 t 的节点数， $\text{ec}_k(t)$ 为面外一跳邻居中含类型 t 的节点数。该分数衡量类型 t 对当前面的“专属程度”：若某类型集中分布在面内而在外部邻居中罕见，则得分高；若某类型（如走廊）遍布各相邻面，则其外部计数大、得分被压低，从而避免走廊类型“污染”相邻房间的投票结果。同分时按固定优先序 (bathroom > bedroom > living_room > kitchen > corridor > dining_room > other) 取最靠前者。最终输出各面的房间类型 $\{r_k\}$ 与对应多边形，即为完整的矢量平面图。

最小度约束 图拓扑生成阶段在补边序列 (SEP 之后) 施加**最小度约束**：若当前图中存在度数小于 2 的节点，则在 logit 采样前将 EOS_G 对应的 logit 置为 $-\infty$ ，强制模型继续生成补边，直至所有节点满足 $\deg(v_i) \geq 2$ 。

该约束的几何动机在于：顶点图中每个节点代表房间多边形的一个角点，角点至少需连接两条边才能构成有效的多边形转角。度数为 1 的悬挂节点无法参与闭合多边形的构造，会导致后处理渲染时出现孤立线段或破碎轮廓。通过在推理阶段以零额外训练代价强制施加此约束，可显著提升生成图的几何合格率。

完整推理流程如算法 1 所示。

Algorithm 1 PlanDiffusion 推理

Require: 文本描述 $\mathcal{T}$

Ensure: 房间多边形列表 $\mathcal{F}$, 各面房间类型 $\{r_k\}$

```
1: // Step 1: 图拓扑生成
2: 以  $\mathcal{T}$  为前缀, 采样节点数  $N \sim p_{\theta_1}(\cdot | \mathcal{T}, \text{BOS\_G})$ , 屏蔽  $N < 9$  的候选 token {C5:  $N \geq 9$ }
3: for  $k = 1, 2, \dots, N - 1$  do
4:   屏蔽编号  $\geq k$  的节点 token 及 SEP
5:   采样父节点  $p_k \sim p_{\theta_1}(\cdot | s_{<\text{cur}})$  {C1:  $p_k < k$ ; C2: SEP 时机}
6: end for
7: 强制插入 SEP
8: while 上一步未采样到 EOS_G do
9:   if  $\forall i: \deg(v_i) \geq 2$  then
10:    开放 EOS_G
11:   end if
12:   采样第一端点  $u \sim p_{\theta_1}(\cdot | s_{<\text{cur}})$  {C4: 度  $\geq 2$  方可结束}
13:   if  $u = \text{EOS\_G}$  then
14:    退出循环
15:   else
16:    屏蔽与  $u$  构成三角环或已相连的节点 token
17:    采样第二端点  $v \sim p_{\theta_1}(\cdot | s_{<\text{cur}})$ , 将边  $(u, v)$  加入  $\mathbf{A}$  {C3: 禁三角}
18:   end if
19: end while
20: 解析序列得  $\mathbf{A} \in \{0, 1\}^{N \times N}$ , 节点掩码  $\mathbf{m}$ 
21: // Step 2: 节点坐标扩散
22: 采样初始噪声  $\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 
23: for  $t = T-1, T-2, \dots, 0$  do
24:    $\hat{\epsilon} = f_{\theta_2}(\mathbf{x}_t, t, \mathbf{A}, \mathbf{m}, \mathcal{T})$ 
25:    $\mu_\theta \leftarrow \frac{1}{\sqrt{\alpha_t}} \left( \mathbf{x}_t - \frac{\beta_t}{\sqrt{1 - \alpha_t}} \hat{\epsilon} \right)$ 
26:    $\mathbf{x}_{t-1} \leftarrow \mu_\theta + \sqrt{\tilde{\beta}_t} \epsilon \cdot \mathbf{1}[t > 0], \quad \epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 
27: end for
28:  $\hat{\mathbf{X}} \leftarrow \mathbf{x}_0$  { $t = 0$  时  $\epsilon$  项为零, 直接取均值}
29: // Step 3: 节点类型预测
30:  $\hat{\mathbf{z}} = f_{\theta_3}(\hat{\mathbf{X}}, \mathbf{A}, \mathbf{m}, \mathcal{T})$ 
31:  $\hat{y}_i = \arg \max_{k \in \{1, \dots, 32\}} \hat{z}_{i,k}, \quad \forall i$ 
32: // Step 4: 面提取与房间类型投票
33:  $\mathcal{F} \leftarrow \text{FINDFACES}(\hat{\mathbf{X}}, \mathbf{A})$  {半边遍历, 排除最大无界面}
34: for 每个面  $f_k \in \mathcal{F}$  do
35:    $\text{score}(t) \leftarrow \frac{|\{i \in f_k : t \in \hat{y}_i\}|}{|\{j \notin f_k : j \in \mathcal{N}(f_k), t \in \hat{y}_j\}| + 1}, \quad \forall t$ 
36:    $r_k \leftarrow \arg \max_t \text{score}(t)$ , 同分时按固定优先序取最前者
37: end for
38: return 房间多边形  $\mathcal{F}$ , 各面房间类型  $\{r_k\}$ 
```

4 实验

4.1 实验设置

评估指标 我们从图拓扑合法性、坐标回归精度和节点类型预测三个维度评估各子模块, 并以图结构分布指标衡量端到端生成质量。所有指标均在 8,000 条独立测试集上计算。

- **图有效率 (Graph Validity Rate, GVR)**: 生成图中连通且无孤立节点的样本占比, 反映图拓扑生成的合法性。
- **度分布 KL 散度 (Degree KL)**: 生成图与真实图的节点度分布之间的 KL 散度, 衡量端到端生成的图结构分布质量。
- **节点数分布 KL 散度 (Node-count KL)**: 生成图与真实图的节点数分布之间的 KL 散度, 衡量模型对平面图规模的建模能力。
- **坐标 RMSE (Coord-RMSE)**: 给定真实图结构条件下, 去噪预测坐标与真实坐标的均方根误差,

衡量节点坐标扩散子模块的回归精度。

- **类型准确率 (Type Acc.):** 给定真实坐标和图结构条件下, 节点类型预测与真实类型的匹配率, 衡量类型预测子模块的分类精度。

相关方法对比 由于现有方法在输入模态、数据集和图表示方式上与本文存在根本差异, 难以在统一评估协议下进行定量对比。表 3 从方法特性角度对比各代表性工作。

表 3: 方法特性对比

方法	输入模态	显式图结构	端到端文本驱动	拓扑约束
Architext [2]	文本	×	✓	×
HouseDiffusion [12]	气泡图	✓	×	部分
ChatHouseDiffusion [10]	文本	×	✓	×
PlanDiffusion (本文)	文本	✓	✓	✓

实现细节 三个子模块均在单张 NVIDIA GPU 上独立训练。图拓扑生成 (LlamaForCausalLM, 约 20M 参数) 训练共 150 epoch (预训练 50 + 微调 100), batch size 64, 学习率余弦退火 $10^{-4} \rightarrow 10^{-5}$ 。节点坐标扩散 (NodeDiffusionTransformer, 约 15M 参数) 训练 200k steps, batch size 64。节点类型预测 (NodeTypeClassifier, 约 15M 参数) 训练 500k steps, batch size 64。推理时三阶段串联执行: 图拓扑生成 (自回归解码) $\rightarrow$ 坐标扩散 (DDPM 1000 步逆采样) $\rightarrow$ 类型分类 (单次前向) $\rightarrow$ render.py 渲染输出。[TODO: 补充: 具体训练硬件型号、各阶段训练时长、端到端推理耗时。]

4.2 主实验结果

表 4 报告了 PlanDiffusion 各子模块的定量评估结果, 测试集共 10,000 条样本。由于现有方法与本文在输入模态、数据集及图表示方式上均不一致, 此处仅报告本文方法的完整指标。

表 4: PlanDiffusion 各子模块定量结果

子模块	指标	结果
图拓扑生成 (θ_1)	GVR $\uparrow$	[TODO:]
	Degree KL $\downarrow$	[TODO:]
	Node-count KL $\downarrow$	[TODO:]
节点坐标扩散 (θ_2)	Coord-RMSE $\downarrow$	[TODO:]
节点类型预测 (θ_3)	Type Acc. $\uparrow$	[TODO:]

[TODO: 填入实验数值后删除本行。]

4.3 消融实验

4.3.1 推理约束消融 (图拓扑生成)

表 5 在相同模型权重下, 逐步加入五个解码约束, 评估图结构合法性指标的变化。**图有效率 (GVR):** 生成图连通且无孤立节点的样本占比; **无三角率:** 生成图中不含三节点闭环的比例; **最小度合格率:** 所有节点度数 ≥ 2 的样本占比。

表 5: 推理约束消融: 逐步启用解码约束对图合法性的影响 (测试集 1000 条)

约束配置	C1	C2	C3	C4	C5	GVR $\uparrow$
无约束	×	×	×	×	×	[TODO:]
+C1 (因果树 $p_k < k$)	✓	×	×	×	×	[TODO:]
+C2 (SEP 时机控制)	✓	✓	×	×	×	[TODO:]
+C3 (禁三节点环)	✓	✓	✓	×	×	[TODO:]
+C4 (最小度 ≥ 2)	✓	✓	✓	✓	×	[TODO:]
+C5 ($N \geq 9$)	✓	✓	✓	✓	✓	[TODO:]

[TODO: 填入约束消融数值后删除本行。]

4.3.2 注意力结构消融 (节点坐标扩散)

为验证双流注意力设计的有效性, 我们在相同数据集和相同训练步数下分别从头训练三个结构变体, 并在测试集上对比坐标回归精度 (表 6)。三个变体除注意力结构外其余超参数完全一致。

表 6: 注意力结构消融: 各变体独立训练后的坐标扩散精度对比

注意力变体	描述	Coord-RMSE↓
仅邻接局部注意力 (AdjAttn only)	每节点仅关注直连邻居	[TODO:]
仅全局注意力 (GlobalAttn only)	节点间无掩码全局自注意力	[TODO:]
双流 (AdjAttn + GlobalAttn)	局部 + 全局并行, 本文完整模型	[TODO:]

[TODO: 填入注意力消融数值后删除本行。]

4.4 定性结果

[TODO: 插入端到端生成结果图: 每行为一个文本条件, 展示生成的顶点图 (含边和节点类型着色) 以及 render.py 输出的彩色平面图。]

图 7: PlanDiffusion 端到端生成结果。每组从左至右依次为: 输入文本描述、生成顶点图 (节点按组合类型着色)、渲染平面图 (房间按类型填色, 标注房间名)。

[TODO: 填入定性结果图后删除本行。]

5 结论

本文提出了 PlanDiffusion, 一种以图结构为中间表示的文本驱动住宅平面图生成框架。通过将生成任务分解为自回归图拓扑生成与节点坐标扩散两个阶段, 本方法在保证房间连通拓扑合法性的同时, 实现了从自然语言到矢量平面图的端到端生成。

为支撑模型训练, 我们构建了 PlanText-150K 数据集, 包含 149,609 条具有高质量自然语言描述的平面图样本, 是目前规模最大的带文本标注住宅平面图数据集之一。

[TODO: 实验结果完成后补充定量结论。]

5.1 未来工作

生成质量与场景扩展 探索更长文本条件下的生成质量提升, 以及多楼层平面图的生成能力。引入 DDIM 等加速采样策略以降低推理延迟, 并研究以离散图扩散模型 [14] 替代自回归图序列生成, 以提升图拓扑生成对文本空间关系指令的遵循能力。

基于强化学习的文本指令对齐 当前节点坐标扩散模块以 MSE 噪声预测为唯一训练目标, 缺乏对文本指令遵循程度的显式优化信号。未来可借鉴 DDPO (Denoising Diffusion Policy Optimization) 框架, 将去噪扩散的多步逆采样过程建模为序列决策问题, 以图有效率、文本-布局一致性等可量化指标构造奖励函数, 通过策略梯度直接优化最终生成质量, 从而在不改变模型结构的前提下显著提升生成平面图对文本空间关系描述的遵循能力。

文本-图结构对比预训练 当前节点坐标扩散模块与节点类型预测模块的文本编码器均采用冻结的 BERT-base, 文本语义空间与平面图几何空间之间缺乏显式对齐, 仅依赖交叉注意力隐式建立关联。未来可借鉴 CLIP [11] 的双塔对比学习框架: 以 BERT 为文本塔, 以图神经网络或 Transformer pooling 为图塔, 将文本描述与对应的邻接图 $\mathbf{A}$ 、节点坐标 $\mathbf{X}$ 编码为同维嵌入, 通过 InfoNCE 对比损失在大规模平面图-文本数据上对齐两塔表示; 微调后的 BERT 再分别替换坐标扩散与类型预测模块的文本编码器, 使文本条件对节点坐标和类型生成的引导能力得到显式增强。

基于 LLM Agent 的局部精修 PlanDiffusion 输出的四元组 (邻接图、节点坐标、节点类型、房间面类型) 构成了结构化、可操作的中间表示。尽管大语言模型在从零生成精确坐标方面能力有限 [1], 但在已有初稿的基础上, 对单一节点坐标的小幅平移、局部增删边、节点类型修改等增量操作的自然语言指令理解具备一定能力。以 PlanDiffusion 生成结果为初稿, 引入 LLM Agent 接受建筑师的自然语言反馈并执行局部结构修改, 可构建面向建筑规划师的交互式辅助工具, 实现“粗粒度扩散生成 + 细粒度语言驱动精修”的人机协同设计 workflow。

参考文献

- [1] W. Feng, W. Zhu, T.-j. Fu, V. Jampani, A. Akula, X. He, S. Basu, X. E. Wang, and W. Y. Wang. Layoutgpt: Compositional visual planning and generation with large language models. In *NeurIPS*, 2023.
- [2] T. Galanos, A. Liapis, and G. N. Yannakakis. Archtext: Language-driven generative architecture design. *arXiv preprint arXiv:2303.07519*, 2023.
- [3] J. Ho, A. Jain, and P. Abbeel. Denoising diffusion probabilistic models. *NeurIPS*, 2020.

- [4] S. Leng, Y. Zhou, H. Hao, X. Shi, and X. Lu. Tell2design: A dataset for language-guided floor plan generation. In *ACL*, 2023.
- [5] R. Liao, Y. Li, Y. Song, S. Wang, W. Hamilton, D. Duvenaud, R. Urtasun, and R. Zemel. Efficient graph generation with graph recurrent attention networks. In *NeurIPS*, 2019.
- [6] I. Loshchilov and F. Hutter. Decoupled weight decay regularization. In *ICLR*, 2019.
- [7] P. Micikevicius, S. Narang, J. Alben, G. Diamos, E. Elsen, D. Garcia, B. Ginsburg, M. Houston, O. Kuchaiev, G. Venkatesh, and H. Wu. Mixed precision training. In *ICLR*, 2018.
- [8] N. Nauata, K.-H. Chang, C.-Y. Cheng, G. Mori, and Y. Furukawa. House-gan: Relational generative adversarial networks for graph-constrained house layout generation. In *ECCV*, 2020.
- [9] A. Q. Nichol and P. Dhariwal. Improved denoising diffusion probabilistic models. In *ICML*, 2021.
- [10] S. Qin, C. He, Q. Chen, S. Yang, W. Liao, Y. Gu, and X. Lu. Chathousediffusion: Prompt-guided generation and editing of floor plans. *arXiv preprint arXiv:2410.11908*, 2024.
- [11] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, G. Krueger, and I. Sutskever. Learning transferable visual models from natural language supervision. In *ICML*, 2021.
- [12] M. A. Shabani, S. Hosseini, and Y. Furukawa. Housediffusion: Vector floorplan generation via a diffusion model with discrete and continuous denoising. In *CVPR*, 2023.
- [13] H. Touvron, T. Lavril, G. Izacard, et al. Llama: Open and efficient foundation language models. *arXiv preprint arXiv:2302.13971*, 2023.
- [14] C. Vignac, I. Krawczuk, A. Siraudin, B. Wang, V. Cevher, and P. Frossard. Digress: Discrete denoising diffusion for graph generation. In *ICLR*, 2023.
- [15] J. You, R. Ying, X. Ren, W. Hamilton, and J. Leskovec. Graphrnn: Generating realistic graphs with deep auto-regressive models. In *ICML*, 2018.

A 组合类型完整映射表

表 7 列出全部 32 种组合类型的整数 ID 与对应的房间类型集合。房间类型按固定字母序排列 (bathroom < bedroom < corridor < dining_room < kitchen < living_room < other), ID 0 保留为填充标记 (padding)。

表 7: 节点组合类型映射表 (共 32 种, ID 0 为填充)

ID	组合类型 (英文)	ID	组合类型 (英文)
1	bathroom	17	bathroom + kitchen + living_room
2	bedroom	18	bathroom + corridor
3	living_room	19	bathroom + corridor + living_room
4	kitchen	20	bathroom + corridor + kitchen
5	corridor	21	bathroom + corridor + kitchen + living_room
6	dining_room	22	bedroom + living_room
7	other	23	bedroom + kitchen
8	bathroom + bedroom	24	bedroom + kitchen + living_room
9	bathroom + bedroom + living_room	25	bedroom + corridor
10	bathroom + bedroom + kitchen	26	bedroom + corridor + living_room
11	bathroom + bedroom + kitchen + living_room	27	bedroom + corridor + kitchen
12	bathroom + bedroom + corridor	28	bedroom + corridor + kitchen + living_room
13	bathroom + bedroom + corridor + living_room	29	kitchen + living_room
14	bathroom + bedroom + corridor + kitchen	30	corridor + living_room
15	bathroom + living_room	31	corridor + kitchen
16	bathroom + kitchen	32	corridor + kitchen + living_room