

PlanDiffusion：基于自回归图结构生成与 坐标扩散的文本驱动住宅平面图生成

广西大学

2203340115@st.gxu.edu.cn

摘要

住宅平面图的自动化生成是计算机辅助建筑设计的核心问题之一。现有方法或依赖用户手工绘制气泡图作为生成条件，或采用规则模板生成文本描述，缺乏从自然语言到矢量平面图的端到端生成能力，且普遍未将显式图结构引入生成过程以保证拓扑合法性。

本文提出 **PlanDiffusion**，一种以图结构为中间表示的文本驱动住宅平面图生成框架。方法将生成任务分解为三个串联阶段： θ_1 以 LLaMA 自回归模型将文本描述转化为邻接图结构；训练前先通过 CLIP 风格图文对比学习预训练文本-图结构对齐编码器； θ_2 以图结构和对齐后的文本语义为双重条件，通过去噪扩散概率模型（DDPM）与三流注意力网络生成节点坐标；随后经半边遍历提取房间面，并结合视觉语言模型在面粒度标注房间类型，最终渲染输出矢量平面图。为支撑模型训练，我们构建了 **PlanText-150K**——包含 149,950 条平面图样本与 MiMo-V2.5 视觉语言模型生成的高质量自然语言描述的大规模数据集，是目前规模最大的带文本标注住宅平面图数据集之一。

在 10,000 条独立测试集上的定量实验表明， θ_1 在全部解码约束启用后图有效率（GVR）达 100%，度分布 KL 散度为 0.0122； θ_2 在真实推理链路下坐标扩散 Coord-RMSE 为 65.62；房间类型由视觉语言模型（MiMo-V2.5）在面粒度直接标注，**[TODO: 待报告面类型准确率及多模型一致性]**。

1 引言

住宅平面图的自动化生成是计算机辅助建筑设计的核心问题之一。理想的系统应当允许设计师以自然语言表达设计意图（如“客厅居中，两侧各有一间卧室，厨房通过走廊与卫生间相连”），并自动生成与描述一致、拓扑合理的矢量平面图。

早期工作主要依赖图约束或气泡图（bubble diagram）作为生成条件 [9, 13]。这类方法虽能输出几何上连贯的平面图，但气泡图本身仍需由设计师手工绘制，并未从根本上解决“从语言到图纸”的端到端生成问题。Architext [3] 率先将大语言模型引入平面图生成，但其文本描述由规则模板自动生成，语言单一，与真实设计需求存在较大差距。ChatHouseDiffusion [11] 进一步引入 prompt 引导并支持局部编辑，但侧重于像素级图像生成，尚未面向矢量图结构的显式拓扑建模。

本文提出 **PlanDiffusion**，一种以图结构为中间表示的文本驱动平面图生成框架，整体流程如图 1 所示。核心思路是将生成任务分解为三个串联阶段：（1）**图拓扑生成**：以 LLaMA 自回归模型将文本描述转化为平面图的拓扑图结构，包括节点数量与邻接关系；（2）**节点坐标扩散**：以图结构和文本为双重条件，通过去噪扩散概率模型（DDPM）生成每个顶点的二维坐标。显式的图结构中间表示使拓扑约束在扩散过程中始终可控，同时为坐标生成提供了强结构先验；在生成坐标与邻接图确定后，系统通过半边遍历提取房间面，并在面粒度进行语义标注与渲染。

为支撑上述框架的训练，我们在 Architext_v1 [3] 基础上构建了 **PlanText-150K**，一个包含 149,950 条样本的大规模平面图-文本数据集。与原始数据集的模板式描述不同，我们调用 MiMo-V2.5 视觉语言模型对每张平面图生成自然语言描述，并经人工抽查校正，显著提升了文本标注的多样性与自然度。

本文的主要贡献如下：

- 提出以图结构为中间表示的三阶段文本驱动平面图生成框架，在保证拓扑合法性的同时实现端到端的语言条件生成；
- 设计了“BFS 生成树 + 补边”的图序列化格式，使任意连通图均可被自回归语言模型高效建模；
- 构建了 PlanText-150K 数据集，通过 MiMo-V2.5 VLM 自动标注并经人工抽查校正提供高质量自然语言描述，是目前规模最大的带文本标注的住宅平面图数据集之一；
- 设计了三流注意力去噪网络（NodeDiffusionTransformer），并联邻接局部注意力（AdjAttn）、面结构注意力（RoomAttn）与全局注意力（GlobalAttn），分别捕捉节点的局部边约束、房间面约束与全局布局信息，在纯文本条件下高精度恢复节点坐标；并在此基础上扩展四流轮廓条件变体（PlanDiffusion-bnd），以外轮廓节点固定 + BndAttn 提供等价于 ChatHouseDiffusion 轮廓输入的几何约束，实现公平定量对比。




图 1: PlanDiffusion 整体流程。左：图拓扑生成阶段以文本描述为条件，通过 LLaMA 自回归推理生成图结构序列，解析得到顶点图；右：完整三阶段生成过程—— θ_2 以顶点图和文本为条件，通过 DDPM 逆扩散从高斯噪声 ($t = 1000$) 逐步恢复节点坐标 ($t = 0$)；随后通过半边遍历提取房间面，并结合面级语义标注渲染输出彩色平面图。

2 相关工作

2.1 平面图生成

平面图生成方法大致可分为三类。

图约束方法。 House-GAN [9] 将房间邻接图作为条件，以关系生成对抗网络生成各房间的边界框，开创了以图约束驱动布局生成的范式。该类方法对拓扑结构有强控制能力，但需要用户预先提供手绘气泡图，限制了易用性。

扩散模型方法。 HouseDiffusion [13] 提出混合扩散模型，在连续坐标与离散房间标签上联合去噪，直接生成矢量多边形，取得了当时最优的几何质量。其同样以气泡图作为输入条件，不支持自然语言驱动。

语言驱动方法。 Architext [3] 在 250k 合成平面图上微调 GPT 系列模型，实现了从自然语言描述到平面图的直接生成。Tell2Design [5] 构建了语言引导平面图数据集并探索了多种基线方法。ChatHouseDiffusion [11] 将扩散模型与 prompt 引导相结合，支持文本条件生成与局部交互编辑，并以房间边界轮廓作为辅助输入。该方法侧重像素级图像生成，与本文面向矢量图结构的端到端文本驱动生成思路互补。

与上述工作不同，本文在文本和坐标之间引入显式图结构作为中间表示，同时具备语言可控性和拓扑保证。

2.2 自回归图结构生成

将图结构序列化后用自回归模型建模是图生成的经典思路。You et al. [17] 提出 GraphRNN，以节点-边交替序列逐步生成图结构。近年来，基于 Transformer 的方法进一步提升了序列建模能力。DiGress [15] 将图生成建模为离散扩散过程，在分子图和场景图上取得了优秀结果。GRAN [6] 通过自回归块生成稠密图，提升了效率。

本文的图序列化方案受“将图展平为序列”思路的启发 [17]，采用“BFS 生成树 + 补边”格式，使生成树部分（长度固定为 $N - 1$ ）与补边部分（长度可变）结构清晰，便于自回归模型学习。

2.3 扩散模型在布局生成中的应用

DDPM [4] 提出去噪扩散概率模型后，扩散过程被广泛应用于图像、点云、分子构象等结构化数据的生成。在布局生成方向，LayoutDM、DiffLayout 等工作将扩散模型引入 UI 布局、文档排版等任务，取得了较好的多样性与质量均衡。HouseDiffusion [13] 将其引入矢量平面图，验证了扩散模型在几何生成上的优越性。

本文的节点坐标扩散模块在 DDPM 框架下，以图结构（邻接矩阵）和文本（WordPiece token）为双重条件，通过双流注意力机制同时捕捉局部几何约束和全局语义信息，与上述工作在条件化方式上存在本质区别。

3 方法

3.1 问题定义

给定自然语言描述 $\mathcal{T}$ ，目标是生成对应的住宅平面图。我们将平面图表示为带属性的图 $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ ，其中 $\mathcal{V}$ 为节点集合（房间多边形的角点）， $\mathcal{E}$ 为边集合（相邻角点间的连接关系）。每个节点 v_i 附带二维坐标 $\mathbf{c}_i \in \mathbb{R}^2$ ，令 $\mathbf{X} = [\mathbf{c}_1, \dots, \mathbf{c}_N]^T \in \mathbb{R}^{N \times 2}$ ，邻接矩阵 $\mathbf{A} \in \{0, 1\}^{N \times N}$ 。半边遍历在 $(\mathbf{X}, \mathbf{A})$ 上提取所有

有界面 $\mathcal{F} = \{f_k\}$, 每个面对应一个房间多边形, 其房间类型 r_k 由视觉语言模型 (VLM) 标注。

生成任务分解为三个串联阶段:

$$\underbrace{p_{\theta_1}(\mathbf{A} | \mathcal{T})}_{\text{图拓扑生成}} \rightarrow \underbrace{p_{\theta_2}(\mathbf{X} | \mathbf{A}, \mathcal{T})}_{\text{坐标扩散}} \rightarrow \underbrace{r_k = \text{VLM}(\text{render}(\mathbf{X}, \mathbf{A}), f_k, \mathcal{T})}_{\text{VLM 面类型标注}} \quad (1)$$

(1) **图拓扑生成**: 自回归建模 $p_{\theta_1}(\mathbf{A} | \mathcal{T})$, 输出图的连接结构与节点数量; (2) **节点坐标扩散**: 以 $(\mathbf{A}, \mathcal{T})$ 为条件, 通过 DDPM 建模 $p_{\theta_2}(\mathbf{X} | \mathbf{A}, \mathcal{T})$; (3) **面提取与语义标注**: 对生成的几何图执行半边遍历得到房间面, 再将渲染平面图与各面节点编号发送至 VLM, 直接在面粒度输出房间类型 r_k 。上述阶段在推理时串联执行。

3.2 数据集

现有平面图数据集在两个维度上均存在不足: 其一, 文本标注普遍依赖规则模板, 语言单一固定, 无法提供多样化的自然语言条件; 其二, 缺乏结构化的图表示, 难以支撑以图结构为条件的生成模型训练。

Architext_v1 [3] 包含约 300 万条合成住宅平面图记录, 对应约 25 万套独立住宅户型, 是目前可获取的最大规模平面图数据集之一, 因此我们选择以其为基础进行扩展。我们对原始数据进行去重与质量筛选, 最终保留约 150,000 条样本用于训练。然而其文本描述仅为简单模板句 (如 “a house with two bedrooms and one bathroom”), 语言形式单一, 与真实自然语言描述差距显著, 不足以支撑文本条件生成的训练。

为此, 我们在 Architext_v1 基础上构建了 **PlanText-150K**, 从两个维度进行扩展: (1) 引入**顶点图表示**——以房间多边形角点为节点、相邻顶点连接为边, 保留平面图完整的几何拓扑信息, 为图结构条件生成提供结构化输入; (2) 引入**自然语言标注**——调用 MiMo-V2.5 视觉语言模型对每张平面图生成多样化的自然语言描述, 相比规则模板语言更丰富、更贴近真实用户输入, 且成本远低于人工标注, 可规模化应用于大规模数据集构建。数据集样例如图 2 所示。

顶点图表示 我们将平面图表示为**顶点图**: 以房间多边形的全部角点为节点, 以多边形边上相邻顶点的连接为边。由于多个房间可能共享同一顶点 (如卧室与走廊的公共墙角), 每个节点的类型定义为其所属全部房间类型的有序组合, 称为**组合类型 (combo type)**。与使用房间中心点的方案相比, 顶点图保留了平面图完整的几何拓扑信息, 并使图结构与几何形状之间保持一一对应。此外, 与 RPlan [16] 等基于像素图的数据集不同, Architext_v1 的原始数据为矢量格式, 顶点坐标直接对应真实建筑几何尺寸。节点间距离、房间面积等物理量可由坐标直接计算, 无需像素-物理量换算, 为未来引入面积约束、比例约束等建筑规范驱动的生成提供了数据基础。房间类型按固定字母序排列后取有序并集作为组合键, 例如仅属于卫生间的顶点为类型 1 (bathroom), 同时属于卫生间与卧室公共墙角的顶点为类型 8 (bathroom + bedroom)。全部训练样本中共出现 32 种组合类型, 每种分配唯一整数 ID (1-32), 完整映射见附录表 11。

自然语言标注 我们将顶点图渲染为彩色平面图图像, 通过 API 调用小米大模型团队发布的视觉语言模型 MiMo-V2.5 对每张图生成自然语言描述。标注要求直接陈述各房间的位置关系与连通关系, 回避视觉指代词, 使描述可独立于图像作为文本条件使用。标注完成后, 对生成结果进行了人工抽查, 修正明显的房间关系错误与语义不一致之处, 以保证标注质量。

统计 最终数据集包含 **148,615** 条样本 (原始 150,000 条中过滤掉以 WordPiece 分词后文本超过 224 token、图不连通或存在度数小于 2 的节点的样本, 共 1,385 条), 每条样本含邻接矩阵 (40×40)、节点坐标 (40×2)、组合类型 ID (40) 及 WordPiece 文本描述。数据集关键统计如表 1 所示。

表 1: 数据集统计

统计项	最小	均值	最大
样本总数		148,615	
节点数	9	22.4	40
边数	12	28.6	50
单类型节点占比		41.2%	
多类型节点占比		58.8%	
Combo 类型总数		32	

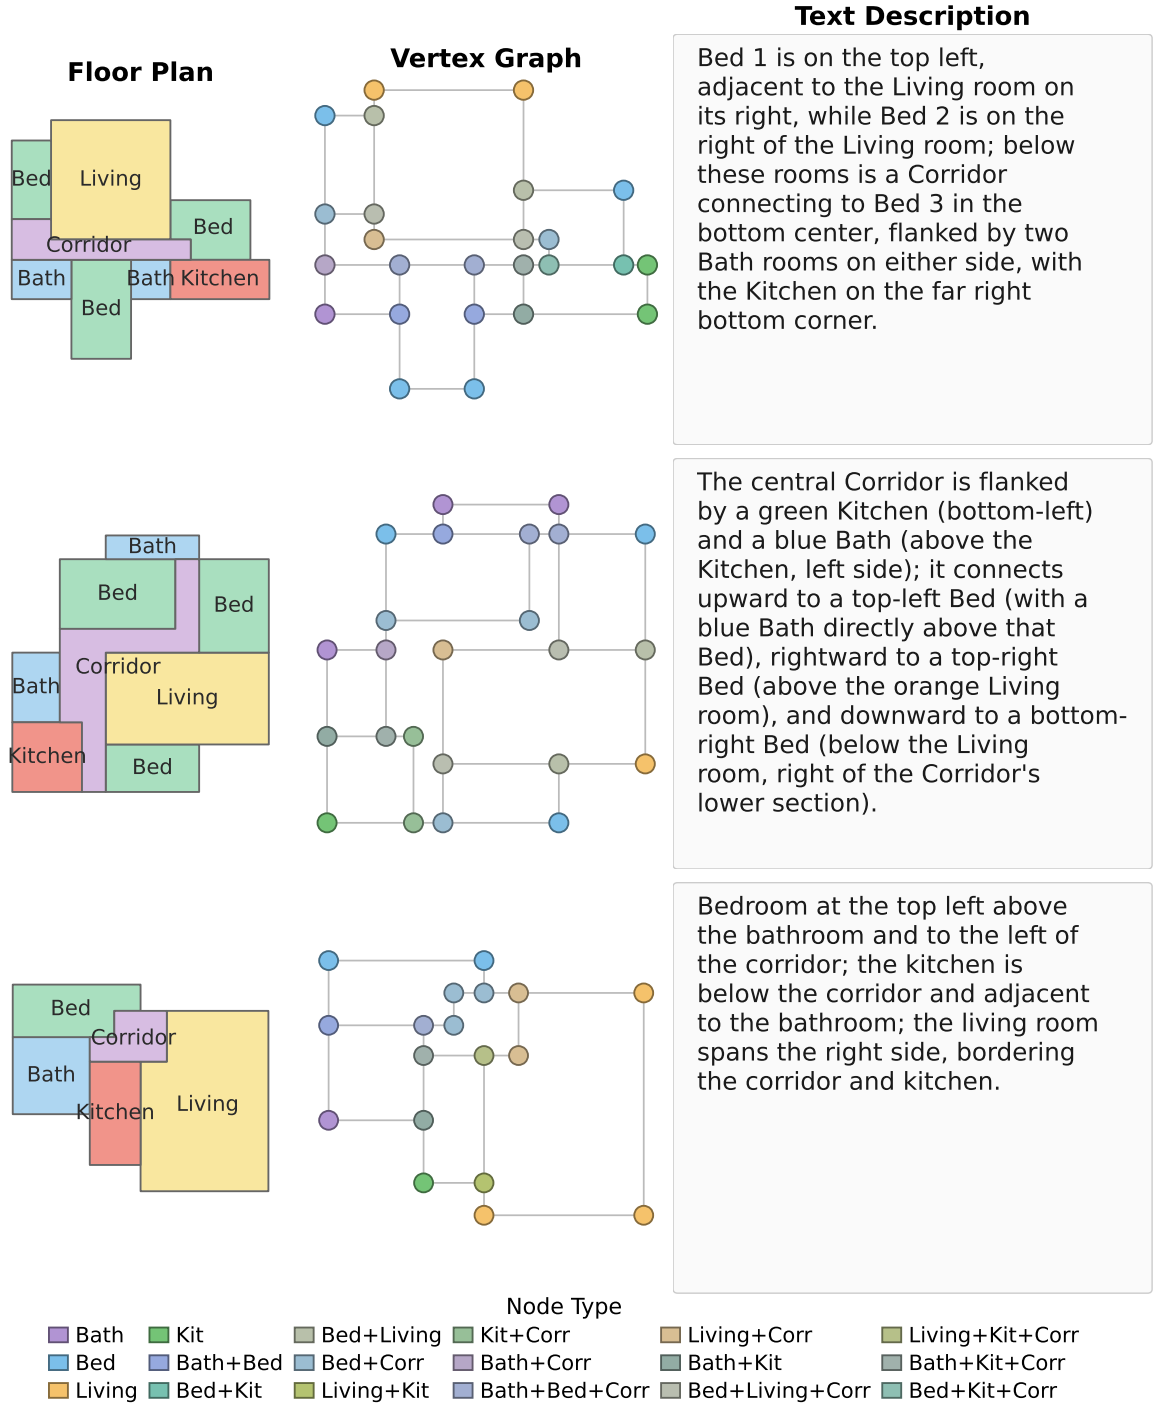


图 2: 数据集样例。每条样本包含住宅平面图渲染 (左)、对应顶点图表示 (中) 及 MiMo-V2.5 生成的自然语言描述 (右)。顶点颜色表示组合类型, 边表示几何连接关系。




图 3: 图序列化的自回归生成过程 ($N = 10$)。蓝色实线为 BFS 生成树边, 红色虚线为补边。从左至右依次为: (1) 生成部分父节点 token 后的局部生成树; (2) 父节点序列生成完毕 (SEP 前) 的完整生成树; (3) 生成前两条补边后的图; (4) 所有补边生成完毕 (EOS_G 前) 的完整图。

3.3 图拓扑生成

3.3.1 词表设计

本阶段采用 BERT-base-uncased 的前 10,000 个 WordPiece token 作为文本词表, 并追加 84 个图结构专用 token, 构成大小为 10,084 的词表, 具体如表 2 所示。

表 2: 图拓扑生成词表布局

ID 范围	Token	说明
0 – 9999	WordPiece token	文本词表 (BERT 前 10k)
10000	PAD	填充
10001	BOS_G	图序列起始
10002	EOS_G	图序列终止
10003	SEP	生成树与补边分隔符
10004–10043	N_k	节点数量 ($N = 1 \sim 40$)
10044–10083	节点 token	节点编号 (0~39)

3.3.2 图序列化格式

给定含 N 个节点的图, 我们将其序列化为:

$$\underbrace{t_1 t_2 \cdots t_L}_{\text{BPE 文本}} \text{BOS_G} \underbrace{N_k}_{N \text{ 个节点}} \underbrace{p_1 p_2 p_3 \cdots p_{N-1}}_{\text{生成树父节点}} \text{SEP} \underbrace{i_1 j_1 i_2 j_2 \cdots}_{\text{补边}} \text{EOS_G} \quad (2)$$

其中生成树通过 BFS 遍历构建, 父节点序列 $p_i = \text{NODE} + \text{parent}(i)$ 记录每个节点在 BFS 树中的父节点; 补边为不属于生成树的额外边, 每条边用两个 token 表示。这一“生成树 + 补边”格式结构规整 (父节点序列长度固定为 $N - 1$), 且任意连通图均可唯一表示。

图 3 展示了自回归生成过程中图结构的逐步构建: 从部分父节点序列对应的局部生成树, 到完整生成树, 再逐步添加补边, 最终恢复完整图拓扑。

令 $\mathbf{s} = (s_1, \dots, s_K)$ 为完整序列 (含文本前缀), 模型建模:

$$p_{\theta_1}(\mathbf{A} \mid \mathcal{T}) = \prod_{k \in \mathcal{I}_g} p_{\theta_1}(s_k \mid s_{<k}) \quad (3)$$

其中 $\mathcal{I}_g$ 为 BOS_G 之后的图 token 下标集合; 文本部分 label 置 -100, 不计入 loss。

3.3.3 模型结构

本阶段采用 LlamaForCausalLM [14] 为自回归主干, 配置为: 隐藏层维度 512, 8 层, 8 头, 前馈维度 1536, 词表大小 10,084, 约 20M 参数。

3.3.4 训练设置

采用 AdamW [7] ($\beta_1=0.9$, $\beta_2=0.95$, $\text{lr} = 10^{-4}$, 余弦退火至 10^{-5}), $\text{grad clip} = 1.0$, FP16 混合精度 [8]。训练数据对每张图从不同起始节点执行 BFS, 共 $\times 12$ 倍数据增强。

3.4 图文对比对齐预训练

仅使用通用 BERT 表征文本会带来一个明显问题: 自然语言中的空间关系 (如 “left of”, “adjacent to”, “connected with”) 并不必然与平面图的拓扑结构和节点几何在同一语义空间中对齐。为此, 在训练坐标扩散模型之前, 本文额外构建一个 CLIP 风格的 **TextGraphAlign** 模块, 对文本描述与真实顶点图进行对比预训练。该模块不直接生成平面图, 而是学习一个共享的文本-图结构嵌入空间, 并将对齐后的 BERT 权重导出为后续扩散模型的文本编码器。

给定一批配对样本 $\{(\mathcal{T}_i, \mathbf{X}_i, \mathbf{A}_i)\}_{i=1}^B$, 图编码器 g_ϕ 接收节点坐标、邻接矩阵、节点掩码和由环检测得到的 room membership。其内部采用与坐标扩散网络一致的三流结构注意力: AdjAttn 捕获直接相邻边关系, RoomAttn 捕获同一房间面的节点关系, GlobalAttn 捕获全局布局关系。多层编码后, 通过 attention pooling 得到图级表示, 并经 MLP 投影与 ℓ_2 归一化:

$$\mathbf{z}_i^g = \frac{g_\phi(\mathbf{X}_i, \mathbf{A}_i, \mathbf{m}_i)}{\|g_\phi(\mathbf{X}_i, \mathbf{A}_i, \mathbf{m}_i)\|_2}. \quad (4)$$

文本编码器 t_ϕ 以 BERT-base-uncased 为主干, 冻结大部分层, 仅解冻最后若干层, 取 [CLS] token 表示, 经 MLP 投影并归一化得到:

$$\mathbf{z}_i^t = \frac{t_\phi(\mathcal{T}_i)}{\|t_\phi(\mathcal{T}_i)\|_2}. \quad (5)$$

训练目标采用对称 InfoNCE 损失。令 τ 为可学习温度, 批内图-文相似度为

$$s_{ij} = \frac{(\mathbf{z}_i^g)^\top \mathbf{z}_j^t}{\tau}, \quad (6)$$

则对比损失为:

$$\mathcal{L}_{\text{align}} = \frac{1}{2} \left[\frac{1}{B} \sum_i -\log \frac{\exp(s_{ii})}{\sum_j \exp(s_{ij})} + \frac{1}{B} \sum_i -\log \frac{\exp(s_{ii})}{\sum_j \exp(s_{ji})} \right]. \quad (7)$$

其中第一项对应 graph-to-text 检索, 第二项对应 text-to-graph 检索。预训练结束后, 保留对齐后的 BERT 权重作为 θ_2 的文本编码器初始化; 在坐标扩散训练与推理阶段, 该 BERT 编码器保持冻结, 只提供稳定的文本条件特征。

3.5 节点坐标扩散

3.5.1 前向过程

以生成的邻接矩阵 $\mathbf{A}$ 和文本 $\mathcal{T}$ 为条件, 对节点坐标 $\mathbf{X} \in \mathbb{R}^{N \times 2}$ 施加高斯 DDPM。采用余弦 (cosine) 噪声调度 [10] ($T = 1000$):

$$\bar{\alpha}_t = \frac{f(t)}{f(0)}, \quad f(t) = \cos^2\left(\frac{t/T + 0.008}{1.008} \cdot \frac{\pi}{2}\right), \quad \beta_t = 1 - \frac{\bar{\alpha}_t}{\bar{\alpha}_{t-1}} \quad (8)$$

令 $\alpha_t = 1 - \beta_t$, 前向过程为:

$$\mathbf{x}_t = \sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}) \quad (9)$$

$t = 0$ 为真实节点坐标, 随时间步增大逐渐被高斯噪声淹没, 至 $t = 1000$ 时坐标分布退化为标准正态分布, 如图 4 所示。

3.5.2 去噪网络

去噪网络 f_{θ_2} (**NodeDiffusionTransformer**) 接收加噪坐标 $\mathbf{x}_t$ 、时间步 t 、邻接矩阵 $\mathbf{A}$ 、节点掩码 $\mathbf{m}$ 和文本 $\mathcal{T}$, 预测坐标噪声:

$$\hat{\boldsymbol{\epsilon}}_{\text{coord}} = f_{\theta_2}(\mathbf{x}_t, t, \mathbf{A}, \mathbf{m}, \mathcal{T}) \quad (10)$$

去噪网络整体架构如图 5 所示。




图 4: 节点坐标的逆扩散过程 ($t = 1000 \rightarrow t = 0$, 从左至右依次排列)。 $t = 1000$ 时节点坐标为纯高斯噪声, 随去噪步骤推进 ($t = 750, 500, 250$), 节点逐步收敛至网格状平面图布局, 至 $t = 0$ 时恢复最终坐标。

节点特征初始化 坐标特征与时间步嵌入直接相加, 构成每个节点的初始隐向量:

$$\mathbf{h}_i^{(0)} = W_c \mathbf{x}_t^{(i)} + \text{MLP}(\gamma(t)) \quad (11)$$

其中 $\gamma(t)$ 为正弦时间步编码, $W_c \in \mathbb{R}^{d \times 2}$, $d = 384$ 。

三流注意力层 平面图节点同时存在三种几何关系: 直接相邻的局部边约束、共处同一房间面的中观面约束、以及全局布局感知。为此, 每个编码器层并联三条独立自注意力流, 输出直接相加后经残差连接与 FFN 处理:

$$\mathbf{h}_i^{(\ell+1)} = \mathbf{h}_i^{(\ell)} + \text{Dropout}\left(\text{AdjAttn}(\mathbf{H}^{(\ell)}) + \text{RoomAttn}(\mathbf{H}^{(\ell)}) + \text{GlobalAttn}(\mathbf{H}^{(\ell)})\right)_i \quad (12)$$

- **邻接局部注意力** AdjAttn: 掩码由邻接矩阵决定, 每个节点仅能关注直连邻居 (含自身):

$$M_{ij}^{\text{adj}} = \begin{cases} 0 & \text{若 } \mathbf{A}_{ij} = 1 \text{ 或 } i = j \\ -\infty & \text{其他} \end{cases} \quad (13)$$

使共边节点在扩散过程中持续交换坐标信息, 维持局部几何一致性。

- **面结构注意力** RoomAttn: 以节点的环成员关系(room membership)为掩码——令 $\mathbf{M}_{\text{rm}} \in \{0, 1\}^{N \times R}$ 为节点-环归属矩阵, 则两节点 i, j 可互相关注当且仅当 $(\mathbf{M}_{\text{rm}} \mathbf{M}_{\text{rm}}^\top)_{ij} > 0$, 即二者共属至少一个房间面。该流使同一房间的所有角点在不感知其他房间节点的前提下相互协调, 弥补了 AdjAttn 仅覆盖一跳邻居的局限。
- **全局注意力** GlobalAttn: 仅屏蔽 padding 节点, 其余节点两两可见, 使每个节点在更新坐标时能感知整体布局分布。

文本条件注入 (CrossAttn): 每层在三流自注意力之后、FFN 之前执行一次交叉注意力, 以节点隐向量为 Q 、文本特征为 $K=V$, 将文本语义注入节点表示:

$$\mathbf{h}_i^{(\ell)} \leftarrow \mathbf{h}_i^{(\ell)} + \text{Dropout}\left(\text{CrossAttn}(\mathbf{H}^{(\ell)}, \mathbf{H}_{\text{text}})\right)_i \quad (14)$$

文本特征 $\mathbf{H}_{\text{text}}$ 由 §3.4 中图文对比预训练后的 aligned BERT 编码后经线性投影 ($768 \rightarrow d$) 得到; 在坐标扩散训练与推理阶段, 该文本编码器保持冻结, 推理全程仅需预计算一次。

共堆叠 6 层, $d = 384$, 6 头, dropout = 0.1, 约 15M 参数。

坐标预测头 编码器输出即为 N 个节点的隐向量 $\{\mathbf{h}_i^{(L)}\}_{i=1}^N \in \mathbb{R}^{N \times d}$ (文本语义已通过各层交叉注意力融合, 序列中始终只含节点 token), 对每个节点独立预测坐标噪声:

$$\hat{\epsilon}_{\text{coord}, i} = \text{Linear}(192 \rightarrow 2) \circ \text{Linear}(384 \rightarrow 192) \circ \text{ReLU} \circ \text{Linear}(384 \rightarrow 384) \left(\mathbf{h}_i^{(L)} \right) \quad (15)$$




图 5: NodeDiffusionTransformer (三流) 架构图。输入的加噪坐标 $\mathbf{x}_t$ 经坐标投影与时间步嵌入相加，构成节点初始隐向量；经 6 层三流注意力编码器处理后，节点特征经 Coordinate Head 预测坐标噪声 $\hat{\epsilon}_{\text{coord}}$ 。

3.5.3 训练目标

训练目标为有效节点上的 MSE:

$$\mathcal{L}_{\text{coord}} = \frac{\sum_i m_i \|\hat{\epsilon}_{\text{coord},i} - \epsilon_i\|^2}{2 \sum_i m_i} \quad (16)$$

其中 m_i 为节点有效掩码 (padding 节点不计入 loss)。

优化器为 AdamW [7] ($\text{lr} = 10^{-4}$, $\text{weight decay} = 10^{-4}$), $\text{grad clip} = 1.0$, FP16 混合精度 [8]。训练数据由原始图通过随机节点重排增强 $\times 8$ 。

3.5.4 推理: DDPM 逆采样

执行标准 DDPM 逆过程 (1000 步):

$$\mathbf{x}_{t-1} \sim \mathcal{N}(\boldsymbol{\mu}_\theta, \tilde{\beta}_t \mathbf{I}), \quad \boldsymbol{\mu}_\theta = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \hat{\epsilon}_{\text{coord}} \right) \quad (17)$$

从 $\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 出发, 逐步去噪得到 $\hat{\mathbf{X}} = \mathbf{x}_0$ 。

3.6 轮廓条件变体: PlanDiffusion-bnd (四流)

动机 PlanDiffusion 的主线设计 (三流, §3.5) 仅以文本和邻接图为条件, 不依赖任何几何先验, 是真正意义上的纯文本驱动生成。然而, ChatHouseDiffusion [11] 等现有方法以建筑外轮廓 (outline) 作为额外输入条件, 为扩散过程提供了强空间约束。在条件信息量不对等的情况下, 直接比较 IoU 并不公平。

为此, 本文引入 **PlanDiffusion-bnd**: 在三流架构基础上, 以顶点图的外轮廓节点作为条件, 新增第四条注意力流 BndAttn, 与 ChatHouseDiffusion 实现等价的几何约束。

外轮廓节点 给定平面图 $(\mathbf{X}, \mathbf{A})$, 通过半边遍历找出面积最大的无界面 (outer face), 其顶点集合即为外轮廓节点 ($\text{is_boundary} = 1$)。在整个扩散过程中, 轮廓节点的坐标 $\mathbf{x}^{\text{bnd}}$ 保持固定、不施加噪声, 仅内部节点参与去噪; 轮廓节点嵌入不携带时间步信息, 始终作为静态空间参考。

四流注意力层 在三流基础上新增轮廓注意力流:

$$\mathbf{h}_i^{(\ell+1)} = \mathbf{h}_i^{(\ell)} + \text{Dropout} \left(\text{AdjAttn} + \text{RoomAttn} + \text{GlobalAttn} + \text{BndAttn} \right)_i^{(\ell)} \quad (18)$$

其中 BndAttn 的 Key/Value 仅来自轮廓节点列 (内部节点列被屏蔽), 使所有节点 (含轮廓节点自身) 在每层均能查询建筑外轮廓的空间分布, 从而以轮廓为锚点约束内部节点的去噪轨迹。

与 ChatHouseDiffusion 的对应关系 ChatHouseDiffusion 以像素级轮廓 mask 约束 U-Net 的生成区域; PlanDiffusion-bnd 以轮廓节点坐标固定 + BndAttn 注入几何约束, 两者均将建筑外轮廓作为强条件, 但生成空间分别为像素图和矢量节点坐标。在相同数据集 (PlanText-150K) 上训练后, 两者具备可比性, 见实验 §4.2 表 7。

3.7 面房间类型标注

坐标扩散完成后, 经半边遍历提取所有有界面 $\{f_k\}$, 每个面对应一个房间多边形。本文直接在面粒度进行房间类型分类: 以平面图渲染图像与各面的节点编号列表为输入, 调用视觉语言模型 (VLM) 对每个面输出房间类型标签 (bathroom / bedroom / living_room / kitchen / corridor / dining_room / other)。

VLM 标注流程 将 θ_2 生成的节点坐标渲染为平面图图像, 同时将各面的节点集合描述为结构化文本 (“Room k : nodes $[i_1, i_2, \dots]$ ”), 拼接文本描述 $\mathcal{T}$ 后, 以图文多模态输入调用 MiMo-V2.5 VLM, 要求其以 JSON 格式输出每个面的房间类型。若解析失败则最多重试 R 次。

[TODO: 报告端到端面类型分类准确率 (与真实面类型对比) 及最终 IoU 结果。]

3.8 推理流程

给定文本 $\mathcal{T}$, 完整推理分四步:

- (1) **图拓扑生成**: 自回归生成图序列 token, 解析得邻接矩阵 $\mathbf{A}$ 与节点数 N 。
- (2) **坐标扩散**: 以 $(\mathbf{A}, \mathbf{m}, \mathcal{T})$ 为条件, 从 $\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 出发执行 1000 步逆扩散, 得到节点坐标 $\hat{\mathbf{X}}$ 。

(3) **面提取与 VLM 房间类型标注**: 以半边遍历 (half-edge traversal) 在平面图 $(\hat{\mathbf{X}}, \mathbf{A})$ 上提取所有有界面, 每个面对应一个房间多边形。将渲染图像与各面节点编号列表发送至 VLM (MiMo-V2.5), 由其直接输出每个面的房间类型 r_k , 最终得到各面的房间类型 $\{r_k\}$ 与对应多边形, 即完整矢量平面图。

最小度约束

- **机制**: 补边阶段若存在度数 < 2 的节点, 将 EOS_G 的 logit 置为 $-\infty$, 强制继续生成补边直至所有节点满足 $\deg(v_i) \geq 2$ 。
- **动机**: 度数为 1 的悬挂节点无法构成有效多边形转角, 会导致渲染时出现孤立线段或破碎轮廓; 该约束以零训练代价在推理阶段消除此类非法结构。

完整推理流程如算法 1 所示。

Algorithm 1 PlanDiffusion 推理

Require: 文本描述 $\mathcal{T}$

Ensure: 房间多边形列表 $\mathcal{F}$, 各面房间类型 $\{r_k\}$

```

1: // Step 1: 图拓扑生成
2: 以  $\mathcal{T}$  为前缀, 采样节点数  $N \sim p_{\theta_1}(\cdot | \mathcal{T}, \text{BOS\_G})$ , 屏蔽  $N < 9$  的候选 token {最小节点数约束}
3: for  $k = 1, 2, \dots, N - 1$  do
4:   屏蔽编号  $\geq k$  的节点 token 及 SEP
5:   采样父节点  $p_k \sim p_{\theta_1}(\cdot | s_{<\text{cur}})$  {C1:  $p_k < k$ ; C2: SEP 时机}
6: end for
7: 强制插入 SEP
8: while 上一步未采样到 EOS_G do
9:   if  $\forall i: \deg(v_i) \geq 2$  then
10:    开放 EOS_G
11:   end if
12:   采样第一端点  $u \sim p_{\theta_1}(\cdot | s_{<\text{cur}})$  {C4: 度  $\geq 2$  方可结束}
13:   if  $u = \text{EOS\_G}$  then
14:     退出循环
15:   else
16:     屏蔽与  $u$  构成三角环或已相连的节点 token
17:     采样第二端点  $v \sim p_{\theta_1}(\cdot | s_{<\text{cur}})$ , 将边  $(u, v)$  加入  $\mathbf{A}$  {C3: 禁三角}
18:   end if
19: end while
20: 解析序列得  $\mathbf{A} \in \{0, 1\}^{N \times N}$ , 节点掩码  $\mathbf{m}$ 
21: // Step 2: 节点坐标扩散
22: 采样初始噪声  $\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 
23: for  $t = T - 1, T - 2, \dots, 0$  do
24:    $\hat{\epsilon} = f_{\theta_2}(\mathbf{x}_t, t, \mathbf{A}, \mathbf{m}, \mathcal{T})$ 
25:    $\mu_\theta \leftarrow \frac{1}{\sqrt{\alpha_t}} \left( \mathbf{x}_t - \frac{\beta_t}{\sqrt{1 - \alpha_t}} \hat{\epsilon} \right)$ 
26:    $\mathbf{x}_{t-1} \leftarrow \mu_\theta + \sqrt{\tilde{\beta}_t} \epsilon \cdot \mathbf{1}[t > 0], \quad \epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 
27: end for
28:  $\hat{\mathbf{X}} \leftarrow \mathbf{x}_0$  { $t = 0$  时  $\epsilon$  项为零, 直接取均值}
29: // Step 3: 面提取与 VLM 房间类型标注
30:  $\mathcal{F} \leftarrow \text{FINDFACES}(\hat{\mathbf{X}}, \mathbf{A})$  {半边遍历, 排除最大无界面}
31:  $\text{img} \leftarrow \text{RENDER}(\hat{\mathbf{X}}, \mathbf{A})$  {渲染平面图图像}
32: for 每个面  $f_k \in \mathcal{F}$  do
33:    $r_k \leftarrow \text{VLM}(\text{img}, \{i: i \in f_k\}, \mathcal{T})$  {MiMo-V2.5, JSON 输出, 失败重试  $R$  次}
34: end for
35: return 房间多边形  $\mathcal{F}$ , 各面房间类型  $\{r_k\}$ 

```

4 实验

4.1 实验设置

评估指标 我们从图拓扑合法性、坐标回归精度和端到端布局质量三个维度评估各阶段, 并以图结构分布指标衡量端到端生成质量。所有指标均在 9,895 条独立测试集上计算。

- **图有效率 (Graph Validity Rate, GVR)**: 生成图中连通且无孤立节点的样本占比, 反映图拓扑生成的合法性。
- **度分布 KL 散度 (Degree KL)**: 生成图与真实图的节点度分布之间的 KL 散度, 衡量端到端生成的图结构分布质量。
- **节点数分布 KL 散度 (Node-count KL)**: 生成图与真实图的节点数分布之间的 KL 散度, 衡量模型对平面图规模的建模能力。
- **节点数准确率 (Node-count Acc.)**: 生成节点数与真实节点数完全一致 (精确) 或误差在 $\pm k$ 以内的样本占比, 衡量模型对单条样本节点规模的预测精度。
- **坐标 RMSE (Coord-RMSE)**: 给定真实图结构条件下, 去噪预测坐标与真实坐标的均方根误差, 衡量节点坐标扩散子模块的回归精度。
- **端到端 IoU**: 三阶段完整推理后, 以 Shapely 多边形面积计算预测房间布局与真实布局之间的交并比。预测坐标经质心对齐后, 按房间类型分组计算: Micro-IoU 为面积加权全局交并比, Macro-IoU 为各房间类型 IoU 的算术平均。由于 DDPM 逆采样从随机高斯噪声出发, 不同的初始化种子会导致生成结果存在一定方差, 单次采样的评估结果受随机性影响较大, 难以稳定反映模型真实能力。为此, 对每条样本运行 5 次独立推理 (噪声种子各异), 取 5 次结果的平均 IoU 作为最终报告值, 以获得更稳定的定量估计。

基线方法 为实现定量对比, 我们将 ChatHouseDiffusion [11] 在 **PlanText-150K** 上重新训练, 与本文方法共用相同的训练集、验证集与测试集划分。ChatHouseDiffusion 原论文在 RPLAN 数据集上训练, 以像素级平面图图像为生成目标, 以文本描述和房间轮廓 (outline mask) 为双重输入条件。为在我们的矢量数据集上复现该方法, 我们将轮廓由像素 mask 转换为顶点图的外轮廓多边形渲染, 其余训练配置沿用原文设置。

为进一步实现与 ChatHouseDiffusion 的**公平对比**, 本文在 θ_2 的基础上引入轮廓条件变体 **PlanDiffusion-bnd**: 在四流注意力架构 (adj + room + global + bnd) 中, 将外轮廓节点 (is_boundary=1) 的坐标在扩散全程固定 (不加噪), 并通过独立的轮廓注意力流 (bnd_attn) 将轮廓空间约束注入所有内部节点。该变体与 ChatHouseDiffusion 的输入条件等价——均以文本描述和建筑外轮廓为条件——但生成空间为矢量节点坐标而非像素图像。

表 3 从方法特性角度对比各代表性工作。

表 3: 方法特性对比

方法	输入模态	轮廓条件	显式图结构	端到端文本驱动	拓扑约束
Architext [3]	文本	×	×	✓	×
HouseDiffusion [13]	气泡图	×	✓	×	部分
ChatHouseDiffusion [11]	文本	✓	×	✓	×
PlanDiffusion-bnd (本文)	文本	✓	✓	✓	✓
PlanDiffusion-tri (本文)	文本	×	✓	✓	✓

实现细节 三个可训练子模块均在 NVIDIA GPU 上独立训练, 其超参数如表 4 所示。

表 4: 可训练子模块训练配置

子模块	模型	GPU	Batch	Steps	时长
图拓扑生成	LlamaForCausalLM (20M)	RTX 3060 (6 GB)	22	~345 万	~211 h
图文对比对齐	TextGraphAlign (39M 可训练)	RTX 3090 (24 GB)	256	30k	—
节点坐标扩散	NodeDiffusionTransformer (15M)	RTX 3080 (10 GB)	384	~100 万	~201 h

TextGraphAlign 采用 AdamW 优化器, 图编码器与投影头学习率为 10^{-4} , BERT 最后 4 层解冻并使用较小学习率 10^{-5} , weight decay 为 10^{-2} , warmup 500 steps, batch size 为 256, 总训练 30k steps。验证时报告双向检索准确率 (graph-to-text 与 text-to-graph), 并保存验证损失最低的 aligned BERT 供后续 NodeDiffusionTransformer 使用。

推理时各阶段串联执行: 图拓扑生成 (自回归解码) → 坐标扩散 (DDPM 1000 步逆采样) → 面提取与语义标注 → 渲染输出。单条样本端到端推理耗时如表 5 所示。DDPM 逆采样 (θ_2) 为主要瓶颈, 占总耗时约 95%; 面提取与渲染阶段耗时可忽略不计。

表 5: 端到端推理各阶段耗时 (单条样本, $n_{\text{nodes}} = 23$)

设备	θ_1 (自回归)	θ_2 (DDPM)	面提取	渲染	合计
RTX 3060 Laptop GPU	0.60 s	13.43 s	0.02 s	<0.01 s	14.05 s
Intel Core i5-11400 CPU	1.82 s	28.61 s	0.34 s	<0.01 s	30.77 s

4.2 主实验结果

表 6 报告了 PlanDiffusion 主要模块与端到端布局的定量评估结果, 测试集共 9,895 条样本。由于现有方法与本文在输入模态、数据集及图表示方式上均不一致, 此处仅报告本文方法的完整指标。其中 Coord-RMSE 以 θ_1 生成的邻接矩阵 (而非真实邻接矩阵) 作为 θ_2 的条件输入, 反映真实推理链路下的坐标扩散精度; 端到端布局 IoU 在 9,895 条测试样本、5 次独立推理取平均后, 经坐标后处理 (§4.3.3) 达到 Micro-IoU 22.46%、Macro-IoU 21.27%, 与同类文本驱动方法 HouseTune [18] (Micro 21.84%、Macro 17.75%, RPLAN 数据集) 处于相近水平; 由于两者使用不同数据集与不同评估协议 (像素级 vs. 多边形面积), 此处仅作参考性对比。

注意, §4.3 消融实验中的 Coord-RMSE (表 9) 使用真实邻接矩阵和 6k 子集数据, 与本表不可直接比较: 主结果使用 θ_1 推理链路引入的误差邻接矩阵, 测试集亦为独立的 10k 样本, 因此主结果 RMSE (65.62) 高于消融中的完整模型 (61.58) 属正常现象。

表 6: PlanDiffusion 主要模块与端到端布局定量结果

模块/阶段	指标	结果
图拓扑生成 (θ_1)	GVR $\uparrow$	100.0%
	Degree KL $\downarrow$	0.0122
	Node-count KL $\downarrow$	0.0057
	节点数准确率 (精确) $\uparrow$	22.59%
	节点数准确率 (± 1) $\uparrow$	57.39%
	节点数准确率 (± 2) $\uparrow$	76.39%
节点坐标扩散 (θ_2 , 三流)	Coord-RMSE $\downarrow$	65.62
端到端布局——PlanDiffusion-tri (5-roll 平均, 含后处理)	Micro-IoU $\uparrow$	22.46%
	Macro-IoU $\uparrow$	21.27%

表 7: 轮廓条件对比: ChatHouseDiffusion vs. PlanDiffusion-bnd (均在 PlanText-150K 上训练)

方法	轮廓条件形式	Micro-IoU $\uparrow$	Macro-IoU $\uparrow$
ChatHouseDiffusion [11]	像素轮廓 mask	89.09%	87.24%
PlanDiffusion-bnd (本文)	轮廓节点固定	91.15%	89.88%
PlanDiffusion-tri (本文, 主线)	无 (纯文本)	22.46%	21.27%

4.3 消融实验

4.3.1 推理约束消融 (图拓扑生成)

表 8 在相同模型权重下, 逐步加入四个解码约束, 评估图结构合法性指标的变化。四个约束定义如下: **C1** (因果树约束): 生成第 k 个节点的父节点时, 仅允许从已生成的节点 $0 \sim k-1$ 中选取, 保证生成树的因果合法性; **C2** (SEP 时机控制): 生成恰好 $N-1$ 个父节点后强制插入 SEP, 防止生成树提前或延迟终止; **C3** (禁三节点环): 添加补边时禁止形成三节点闭环, 保证图无三角结构; **C4** (最小度约束): 在所有节点度数均 ≥ 2 之前禁止发出 EOS_G, 保证无孤立或悬挂节点。评估指标: 图有效率 (GVR) 为生成图连通且无孤立节点的样本占比。

4.3.2 注意力结构消融 (节点坐标扩散)

为验证双流注意力设计的有效性, 我们在相同数据集和相同训练步数下分别从头训练三个结构变体, 并对比坐标回归精度 (表 9)。三个变体除注意力结构外其余超参数完全一致。

训练数据为原始 6k 平面图数据集经 8 倍坐标增强后所得约 48k 样本, 三个变体均以 batch size 384 各独立训练 250k steps (仅用于结构对比, 步数少于主模型); 定量评估采用从同一 6k 数据集中随机抽取的 1000 条样本, 以 Coord-RMSE 衡量完整 DDPM 1000 步逆采样后的坐标重建精度; 定性可视化 (图 6)

表 8: 推理约束消融: 逐步启用解码约束对图合法性的影响 (C1-C4 定义见正文)

约束配置	C1	C2	C3	C4	GVR $\uparrow$
无约束	×	×	×	×	99.6%
+C1	✓	×	×	×	99.9%
+C2	✓	✓	×	×	100.0%
+C3	✓	✓	✓	×	100.0%
+C4	✓	✓	✓	✓	100.0%

同样采用完整 DDPM 1000 步逆采样以保证生成质量。由于三变体在定量评估中均使用相同的 DDPM 1000 步配置, 各变体之间的相对比较可有效反映注意力结构本身的影响。

表 9: 注意力结构消融: 各变体独立训练后的坐标扩散精度对比 (DDPM 1000 步)

注意力变体	描述	Coord-RMSE $\downarrow$
AdjAttn only	每节点仅关注直连邻居 (局部边)	80.71
GlobalAttn only	节点间无掩码全局自注意力	68.71
AdjAttn + GlobalAttn (双流)	局部 + 全局并行	[TODO: 待补]
AdjAttn + RoomAttn + GlobalAttn (三流, 本文)	局部 + 面 + 全局并行	61.58

图 6 对变体的生成布局进行定性对比。GlobalAttn only 生成的节点分布散乱、边交叉严重; AdjAttn only 布局较为规整但整体偏移较大; 三流变体 (Ours) 在布局合理性和与真实图的相似度上均最优。RoomAttn 的引入使同一房间面内的所有角点在去噪过程中可以相互感知, 弥补了 AdjAttn 仅覆盖一跳邻居的局限, 显著降低了 Coord-RMSE。

4.3.3 坐标后处理消融 (节点-墙体吸附)

由于 θ_2 独立预测每个节点坐标, 缺乏显式的几何对齐约束, 部分节点在视觉上已贴近某条墙体, 但邻接图中却未建立连接关系, 造成拓扑与几何的不一致, 进而导致多边形提取失败或面积计算偏差。为此, 我们在坐标扩散之后引入一个几何后处理步骤: 若节点 i 到某条边 (j, k) 的垂直距离小于阈值 τ , 则将节点 i 投影到该边上, 并同步更新邻接图——删除直连边 $j-k$, 添加 $i-j$ 和 $i-k$ 两条新边, 使节点 i 正式插入墙体。修正后的坐标与邻接图用于后续面提取、语义标注与 IoU 计算。

表 10 报告了是否启用该后处理对端到端 IoU 的影响 ($\tau = 0.05 \times d_{\text{bbox}}$, d_{bbox} 为有效节点包围盒对角线长度)。

表 10: 节点-墙体吸附后处理消融 (9,895 条测试样本, 5-roll 平均)

方法	Micro-IoU $\uparrow$	Macro-IoU $\uparrow$
w/o 后处理	21.18%	19.81%
w/ 后处理 ($\tau = 0.05$)	22.46%	21.27%

后处理带来 Micro-IoU +1.28%、Macro-IoU +1.46% 的提升, 且 5 次 roll 之间的方差极小 ($< 0.2\%$), 表明该步骤能有效修正几何偏差、提升预测布局与真实布局的面积重叠度。

4.4 定性结果

图 7 展示了五条文本条件下的端到端生成结果。定性结果表明, PlanDiffusion 能够以自然语言文本为条件, 端到端生成结构合理的建筑平面图。尤其是 θ_2 生成的节点坐标 (图 7 第三列) 呈现出平面图特有的网格状空间分布——节点沿水平/垂直方向规整对齐、相邻节点间距均匀, 表明模型在 DDPM 扩散过程中有效学习到了真实平面图节点坐标的空间分布特征。受限于级联式生成架构, 部分样例中房间类型的空间位置与文本描述存在对应偏差, 留待后续端到端联合训练方案改进。

5 结论

本文提出了 PlanDiffusion, 一种以图结构为中间表示的文本驱动住宅平面图生成框架。通过将生成任务分解为图拓扑生成、节点坐标扩散与面级语义标注等阶段, 本方法在保证房间连通拓扑合法性的同时, 实现了从自然语言到矢量平面图的端到端生成。

为支撑模型训练, 我们构建了 PlanText-150K 数据集, 包含 149,950 条具有高质量自然语言描述的平面图样本, 是目前规模最大的带文本标注住宅平面图数据集之一。



图 6: 注意力结构消融定性对比 (5 个测试样本, DDPM 1000 步采样)。每行为同一输入条件下三个变体的生成结果, 列从左至右依次为: Ground Truth、AdjAttn Only、GlobalAttn Only、Dual-stream (本文)。边表示节点间相邻关系。




图 7: PlanDiffusion 端到端生成结果 (5 条自定义文本条件)。每行从左至右依次为: 输入文本描述、 θ_1 生成邻接图 (spring layout)、 θ_2 预测坐标图 (节点统一蓝色)、面级语义标注结果、渲染平面图 (房间按类型填色, 标注房间名)。

定量实验表明，图拓扑生成模块在全部推理约束启用后图有效率（GVR）达到 100%，度分布 KL 散度为 0.0122，节点数分布 KL 散度为 0.0057，验证了”BFS 生成树 + 补边”序列化格式与四项解码约束的有效性。节点坐标扩散模块在真实推理链路（以 θ_1 生成邻接矩阵为条件）下 Coord-RMSE 为 65.62，表明 NodeDiffusionTransformer 能够在图结构与文本的双重条件下有效恢复节点坐标的空间分布。面房间类型标注由视觉语言模型（MiMo-V2.5）在面粒度直接完成，**[TODO: 待补充 VLM 标注准确率及 IoU 结果后更新本段]**。

5.1 未来工作

生成质量与场景扩展 探索更长文本条件下的生成质量提升，以及多楼层平面图的生成能力。研究以离散图扩散模型 [15] 替代自回归图序列生成，以提升图拓扑生成对文本空间关系指令的遵循能力。

基于强化学习的文本指令对齐 当前节点坐标扩散模块以 MSE 噪声预测为唯一训练目标，缺乏对文本指令遵循程度的显式优化信号。未来可借鉴 DDPO [1] (Denoising Diffusion Policy Optimization) 框架，将去噪扩散的多步逆采样过程建模为序列决策问题，以图有效率、文本-布局一致性等可量化指标构造奖励函数，通过策略梯度直接优化最终生成质量，从而在不改变模型结构的前提下显著提升生成平面图对文本空间关系描述的遵循能力。

文本-图结构对比预训练 当前节点坐标扩散模块的文本编码器采用冻结的 BERT-base，文本语义空间与平面图几何空间之间缺乏显式对齐，仅依赖交叉注意力隐式建立关联。未来可借鉴 CLIP [12] 的双塔对比学习框架：以 BERT 为文本塔，以图神经网络或 Transformer pooling 为图塔，将文本描述与对应的邻接图 **A**、节点坐标 **X** 编码为同维嵌入，通过 InfoNCE 对比损失在大规模平面图-文本数据上对齐两塔表示；微调后的 BERT 再替换坐标扩散模块的文本编码器，使文本条件对节点坐标生成的引导能力得到显式增强。

基于 LLM Agent 的局部精修 PlanDiffusion 输出的结构化结果（邻接图、节点坐标与房间面类型）构成了结构化、可操作的中间表示。尽管大语言模型在从零生成精确坐标方面能力有限 [2]，但在已有初稿的基础上，对单一节点坐标的小幅平移、局部增删边、房间面类型修改等增量操作的自然语言指令理解具备一定能力。以 PlanDiffusion 生成结果为初稿，引入 LLM Agent 接受建筑师的自然语言反馈并执行局部结构修改，可构建面向建筑规划师的交互式辅助工具，实现”粗粒度扩散生成 + 细粒度语言驱动精修”的人机协同设计工作流。

参考文献

- [1] K. Black, M. Janner, Y. Du, I. Kostrikov, and S. Levine. Training diffusion models with reinforcement learning. In *ICLR*, 2024.
- [2] W. Feng, W. Zhu, T.-j. Fu, V. Jampani, A. Akula, X. He, S. Basu, X. E. Wang, and W. Y. Wang. Layoutgpt: Compositional visual planning and generation with large language models. In *NeurIPS*, 2023.
- [3] T. Galanos, A. Liapis, and G. N. Yannakakis. Archtext: Language-driven generative architecture design. *arXiv preprint arXiv:2303.07519*, 2023.
- [4] J. Ho, A. Jain, and P. Abbeel. Denoising diffusion probabilistic models. *NeurIPS*, 2020.
- [5] S. Leng, Y. Zhou, H. Hao, X. Shi, and X. Lu. Tell2design: A dataset for language-guided floor plan generation. In *ACL*, 2023.
- [6] R. Liao, Y. Li, Y. Song, S. Wang, W. Hamilton, D. Duvenaud, R. Urtasun, and R. Zemel. Efficient graph generation with graph recurrent attention networks. In *NeurIPS*, 2019.
- [7] I. Loshchilov and F. Hutter. Decoupled weight decay regularization. In *ICLR*, 2019.
- [8] P. Micikevicius, S. Narang, J. Alben, G. Diamos, E. Elsen, D. Garcia, B. Ginsburg, M. Houston, O. Kuchaiev, G. Venkatesh, and H. Wu. Mixed precision training. In *ICLR*, 2018.
- [9] N. Nauata, K.-H. Chang, C.-Y. Cheng, G. Mori, and Y. Furukawa. House-gan: Relational generative adversarial networks for graph-constrained house layout generation. In *ECCV*, 2020.
- [10] A. Q. Nichol and P. Dhariwal. Improved denoising diffusion probabilistic models. In *ICML*, 2021.
- [11] S. Qin, C. He, Q. Chen, S. Yang, W. Liao, Y. Gu, and X. Lu. Chathousediffusion: Prompt-guided generation and editing of floor plans. *arXiv preprint arXiv:2410.11908*, 2024.
- [12] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, G. Krueger, and I. Sutskever. Learning transferable visual models from natural language supervision. In *ICML*, 2021.
- [13] M. A. Shabani, S. Hosseini, and Y. Furukawa. Housediffusion: Vector floorplan generation via a diffusion

- model with discrete and continuous denoising. In *CVPR*, 2023.
- [14] H. Touvron, T. Lavril, G. Izacard, et al. Llama: Open and efficient foundation language models. *arXiv preprint arXiv:2302.13971*, 2023.
- [15] C. Vignac, I. Krawczuk, A. Siraudin, B. Wang, V. Cevher, and P. Frossard. Digress: Discrete denoising diffusion for graph generation. In *ICLR*, 2023.
- [16] W. Wu, X.-M. Fu, R. Tang, Y. Wang, Y.-H. Qi, and L. Liu. Data-driven interior plan generation for residential buildings. *ACM Transactions on Graphics (TOG)*, 38(6):1–12, 2019.
- [17] J. You, R. Ying, X. Ren, W. Hamilton, and J. Leskovec. Graphrnn: Generating realistic graphs with deep auto-regressive models. In *ICML*, 2018.
- [18] Z. Zong, G. Chen, Z. Zhan, F. Yu, and G. Tan. Housetune: Two-stage floorplan generation with llm assistance. *arXiv preprint arXiv:2411.12279*, 2024.

A 组合类型完整映射表

表 11 列出全部 32 种组合类型的整数 ID 与对应的房间类型集合。房间类型按固定字母序排列 (bathroom < bedroom < corridor < dining_room < kitchen < living_room < other), ID 0 保留为填充标记 (padding)。

表 11: 节点组合类型映射表 (共 32 种, ID 0 为填充)

ID	组合类型 (英文)	ID	组合类型 (英文)
1	bathroom	17	bathroom + kitchen + living_room
2	bedroom	18	bathroom + corridor
3	living_room	19	bathroom + corridor + living_room
4	kitchen	20	bathroom + corridor + kitchen
5	corridor	21	bathroom + corridor + kitchen + living_room
6	dining_room	22	bedroom + living_room
7	other	23	bedroom + kitchen
8	bathroom + bedroom	24	bedroom + kitchen + living_room
9	bathroom + bedroom + living_room	25	bedroom + corridor
10	bathroom + bedroom + kitchen	26	bedroom + corridor + living_room
11	bathroom + bedroom + kitchen + living_room	27	bedroom + corridor + kitchen
12	bathroom + bedroom + corridor	28	bedroom + corridor + kitchen + living_room
13	bathroom + bedroom + corridor + living_room	29	kitchen + living_room
14	bathroom + bedroom + corridor + kitchen	30	corridor + living_room
15	bathroom + living_room	31	corridor + kitchen
16	bathroom + kitchen	32	corridor + kitchen + living_room